



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia artificial
Título del Trabajo Fin de Estudios

Trabajo fin de estudio presentado por:	Francesc Aguiló y Ricard Martín
Tipo de trabajo:	Piloto experimental
Director/a:	Guillermo Torralba Elipe
Fecha:	

Resumen

Abstract

Índice de contenidos

Resumen	1
Abstract	3
Índice de contenidos	4
Índice de figuras	4
Índice de tablas	5
Organización del trabajo en grupo	7
1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	2
2. Contexto y estado del arte	3
2.1. Contexto del problema	3
2.1.1 Predicción de mercados financieros	3
2.1.2 Riesgo geopolítico y su impacto en mercados	7
2.1.3 Bases de datos de eventos geopolíticos	8
2.1.4 Redes neuronales de grafos	10
2.1.5 Síntesis	11
2.2. Estado del arte	12
2.2.1 Machine learning aplicado al riesgo geopolítico	12
2.2.2 GDELT como fuente de datos para predicción financiera	15
2.2.3 GNN en predicción bursátil	16
2.2.4 Grafos temporales y dinámicos	21
2.3. Conclusiones	22
3. Objetivos concretos y metodología de trabajo	23
3.1. Objetivo general	23
3.2. Objetivos específicos	23
3.3. Metodología del trabajo	23
4. Descripción detallada del experimento	25
4.1 Filtrado de datos	25
4.2 Decisiones técnicas	25
4.3 Arquitectura final	35
5. Descripción de los resultados	41
6. Discusión	41
7. Conclusiones y trabajo futuro	41
7.1. Conclusiones	41
7.2. Líneas de trabajo futuro	41
8. Referencias bibliográficas	42

Índice de figuras

Figura 1. *Ejemplo de figura realizada para nuestro trabajo.*

2

Índice de tablas

Tabla 1. *Organización del trabajo en grupo.*

VIII

Organización del trabajo en grupo

Partes que aborda el TFE

Francesc Aguiló → **Dataset y grafo geopolítico:** Extracción, filtrado y preprocesamiento de datos de GDELT, incluyendo la selección de periodos históricos relevantes, la deduplicación y limpieza del dataset, la obtención y alineación temporal de los datos del S&P 500, y el diseño y construcción del grafo geopolítico (definición de nodos, aristas, atributos y generación de snapshots diarios).

Ricard Martín → **Modelo GNN y evaluación:** Selección e implementación de la arquitectura GNN, el diseño del mecanismo de fusión entre la información geopolítica del grafo y los indicadores financieros del S&P 500, el entrenamiento del modelo, la construcción de un modelo de referencia para comparación, la evaluación mediante métricas de clasificación y la automatización de la predicción diaria.

Distribución y estructura de la memoria

Organización del trabajo en grupo - Desarrollo de la memoria	
Apartado de la memoria	Responsables
Introducción	F. Aguiló y R. Martín
Contexto y estado del arte	F. Aguiló y R. Martín
Objetivos y metodología de trabajo	F. Aguiló y R. Martín
Marco normativo	F. Aguiló y R. Martín
Desarrollo: Dataset y grafo geopolítico	F. Aguiló
Desarrollo: Modelo GNN y evaluación	R. Martín
Conclusiones	F. Aguiló y R. Martín

Fuente: Elaboración propia.

Objetivo del TFE desde el punto de vista de la adquisición de conocimientos

Este TFE incorpora dos áreas diferenciadas: por un lado, la ingeniería de datos y representación del conocimiento aplicada a la transformación de datos geopolíticos en estructuras de grafo y, por otro, el diseño e implementación de arquitecturas de deep learning sobre grafos para predicción financiera. Cada una de estas áreas requiere competencias distintas que, combinadas, aportan una visión completa del proceso desde la obtención del dato hasta la predicción final.

Mecanismos de coordinación empleados

Las herramientas utilizadas para la coordinación son: Trello, Discord, Google Drive y GitHub. Utilizando una organización semanal del trabajo mezclando una reunión semanal con reuniones esporádicas en momentos necesarios.

1. Introducción

1.1. Motivación

La inversión en mercados financieros es un recurso indispensable para la asignación eficiente de capital, la financiación de empresas y estados, la gestión del riesgo y la formación de precios. Desde el surgimiento de la inteligencia artificial, se han intentado aplicar estos modelos para la predicción automatizada de mercado gracias a la gran cantidad de datos de los que disponemos para entrenarlas y el gran potencial que demuestran tener para la gestión de ellos a un nivel inalcanzable para el ser humano (Bao et al., 2025).

Tradicionalmente estos modelos se han basado únicamente en datos financieros, aunque con el desarrollo de nuevos enfoques en el planteamiento de modelos de Inteligencia Artificial cada vez más se están buscando modelos híbridos o más balanceados. Estos nuevos modelos buscan incorporar información externa al mercado, pues el mercado se ve directamente afectado de factores sociales, militares, políticos o científicos entre otros que usando solamente datos económicos no se podrían identificar claramente (Bao et al., 2025; Patel et al., 2025).

Aún con todo esto, que un modelo sea completo y abarque muchos registros distintos no garantiza la viabilidad de este, pues cuantos más datos distintos más difícil se vuelve balancear su aprendizaje y gestionar su sesgo.

En este trabajo se persigue la creación de un modelo de predicción de mercados financieros usando un modelo híbrido aplicado al índice S&P 500, que agrupa las 500 mayores empresas cotizadas en Estados Unidos. El factor diferencial de nuestro modelo es la anexión de un modelo que analice la actualidad geopolítica del entorno que, añadido a la información histórica del S&P 500, ayude al modelo a adelantarse a fluctuaciones considerables del mercado financiero estadounidense.

La idea es la utilización de una base de datos global de eventos geopolíticos para la creación de una red neuronal en forma de grafo relacional (GNN) con la que poder plasmar el estado del mundo y ayudar a entender las razones de algunas variaciones del mercado a corto plazo.

El objetivo final es la creación de un modelo que prediga la subida, bajada o neutralidad del S&P 500 antes de la apertura de mercado para ese día.

1.2.Planteamiento del trabajo




Figura 1. Arquitectura del sistema: GDELT + datos financieros → grafo persistente con decay → HeteroGAT (GATv2) → vector del nodo mercado → clasificación triclase del S&P 500 en t+1. Fuente: Elaboración propia.

1.3.Estructura del trabajo

2. Contexto y estado del arte

2.1.Contexto del problema

En este punto se presentan los fundamentos teóricos sobre los que se sustenta el trabajo, comenzando por la problemática de la predicción de mercados financieros, continuando con el concepto de riesgo geopolítico y su impacto en los mercados. A continuación se describen las bases de datos de eventos geopolíticos disponibles y las redes neuronales de grafos como herramienta técnica para el procesamiento de estos datos, para finalizar con una síntesis de todo lo expuesto.

2.1.1 Predicción de mercados financieros

La predicción de mercados financieros es un objetivo que el ser humano lleva persiguiendo desde la propia invención de estos mercados y, en la actualidad, con el avance de la tecnología y la capacidad de computación, cada vez tenemos más herramientas para ello. Pero la predicción de sistemas tan complejos no es algo trivial que pueda resolverse únicamente con capacidad de cálculo, existen multitud de factores que dificultan enormemente su comprensión:

El primer factor es la no linealidad, en un sistema lineal las consecuencias son respuestas fijas y predecibles a ciertas causas específicas. Pero la estructura caótica y entramada de los mercados financieros cambia las relaciones entre sus elementos de manera opaca al ojo humano debido a su complejidad, convirtiendo un solo movimiento en una sucesión de cambios a primera vista inconexos creando una tormenta a partir de una sola ola.

Otro factor es la volatilidad, cada segundo se crea información nueva que puede o no alterar la visión sobre cualquier elemento remotamente relacionado con el mercado a predecir. Además, esta información puede ser inventada o generada artificialmente por algún interesado para otros fines, lo que desencadena una variación brusca, impredecible e irregular de los precios en cuestión de minutos.

A estos dos factores debemos sumarles la interacción de múltiples variables dinámicas: dependiendo simultáneamente de datos macroeconómicos, situación de las empresas, sentimiento de los inversores, eventos geopolíticos, decisiones de bancos centrales, divisas y

infinitos otros factores que forman un sistema que existe y se ejecuta constantemente, como una cadena infinita de causas y consecuencias donde cada movimiento desencadena otros en todas direcciones.

Cualquier modelo predictivo es, por definición, una simplificación de ese sistema cuya complejidad total es inabarcable, de la misma forma que una simulación física no replica cada interacción de la realidad sino las suficientes para producir un resultado útil, un modelo de predicción financiera busca capturar una fracción suficientemente representativa de las dinámicas de un mercado. Este trabajo se centra en capturar concretamente la fracción geopolítica de esas dinámicas.

Al hablar de la infinita complejidad del mercado, debemos mencionar la hipótesis del mercado eficiente (Fama, 1970), que sostiene la imposibilidad de una predicción consistente al afirmar que los precios de los activos financieros reflejan en todo momento toda la información disponible, lo que implicaría que ningún modelo puede generar ventaja predictiva de forma sostenida. Fama(1970) distingue tres formas de eficiencia: débil (los precios incorporan toda la información histórica), semifuerte (incorporan además toda la información pública) y fuerte (incorporan incluso la información privilegiada). Sin embargo, esta hipótesis ha sido ampliamente cuestionada. Diversos estudios han documentado anomalías e ineficiencias en los mercados (Shiller, 2003), y en particular se ha observado que la información compleja (como la derivada de eventos geopolíticos) no se absorbe de forma instantánea, sino que sus efectos se despliegan progresivamente a lo largo de días o semanas. Es precisamente en ese retardo entre la aparición de la información y su plena incorporación al precio donde los modelos predictivos buscan operar.

Antes del desarrollo de la Inteligencia Artificial ya existían multitud de técnicas para la predicción y el análisis de mercados, las más relevantes son el análisis fundamental y el análisis técnico, que se exponen a continuación:

- El análisis fundamental busca determinar el valor intrínseco de un activo financiero, llamado valor fundamental. Este valor se usa posteriormente para relacionarlo con el valor actual de este mismo activo y determinar si está infravalorado o sobrevalorado.
- El análisis técnico se basa exclusivamente en datos históricos de precio y volumen para intentar predecir movimientos futuros.

Mientras el análisis fundamental se centra en la empresa, el técnico se centra en la acción y sus rendimientos. Son dos corrientes clásicas de análisis de las que este trabajo se distancia al adoptar un enfoque basado en la adición de datos externos al mercado.

Si nos fijamos en los modelos de predicción de mercados financieros que han existido hasta ahora, podemos observar una evolución que intenta esquivar los obstáculos mencionados anteriormente. Por un lado tenemos los modelos estadísticos clásicos, como ARIMA o GARCH. ARIMA (AutoRegressive Integrated Moving Average) es un modelo que se basa en predecir un valor futuro basándose en sus valores pasados y en el error de predicción de esos valores pasados. GARCH (Generalized Autoregressive Conditional Heteroskedasticity) funciona de manera parecida, pero está orientado a modelar la volatilidad, intentando predecir la varianza del precio, pero no su valor o dirección. Ambos modelos basan sus predicciones en relaciones lineales, y como hemos visto anteriormente, las relaciones lineales son casi inexistentes en los movimientos de un mercado.

El gran salto llega con el desarrollo del Machine Learning clásico, con la implementación de técnicas como el Support Vector Machine (SVM) (Cortes y Vapnik, 1995) o el Random Forest (Breiman, 2001), pensados para capturar relaciones no lineales, a diferencia de los modelos estadísticos clásicos. Mientras que SVM busca el hiperplano que permita separar de la mejor manera algo en dos grupos, por ejemplo qué operaciones han sido exitosas o no, Random Forest genera múltiples árboles de decisión, cada uno entrenado con un subconjunto aleatorio de los datos, y combina sus respuestas para producir una predicción más robusta que la de cualquier árbol individual. Este tipo de técnicas mejoran mucho los modelos clásicos, pero fallan cuando buscamos añadir un factor temporal, pues estos modelos tratan cada observación de forma independiente sin considerar su orden cronológico y por ello no incorporan la dimensión temporal de los datos.

Con la llegada del Deep Learning y las redes recurrentes llega la capacidad de entender secuencias complejas y añade la capacidad de que el modelo tenga en cuenta la variable tiempo entre sus parámetros. LSTM (Long Short-Term Memory)(Hochreiter y Schmidhuber, 1997) por ejemplo, es una red neuronal diseñada específicamente para tener en cuenta datos secuenciales, usando una estructura única de celda de memoria que juzga la utilidad de la información para saber en qué caso olvidar y en qué caso recordar. Existen también muchas otras derivadas, como GRU (Gated Recurrent Unit)(Cho et al., 2014), que tiene un funcionamiento similar aunque simplificado.

Finalmente, a día de hoy, los transformers son la arquitectura más puntera y dominante (Vaswani et al., 2017). Se diferencia de las redes recurrentes en el procesamiento de toda la secuencia a la vez y no paso a paso como todos los demás modelos hasta ahora, creando modelos más rápidos en el entrenamiento y mejores en la captación de detalles y relaciones complejas. En la inteligencia artificial aplicada a las finanzas se están aplicando a un ritmo vertiginoso, con modelos como el Temporal Fusion Transformer (TFT)(Lim et al., 2021) creado específicamente para el análisis de series temporales.

A fecha de este trabajo, estas arquitecturas de transformers y redes recurrentes se han aplicado principalmente a datos financieros directos, y cada vez más se abren las puertas a enfoques mixtos para poder representar mejor la totalidad del mercado como se expuso en el principio de este marco teórico. Es en estos enfoques mixtos donde se fundamenta nuestro proyecto, añadiendo una capa de geopolítica a la capa financiera estándar.

2.1.2 Riesgo geopolítico y su impacto en mercados

Caldara e Iacoviello (2022) definen el riesgo geopolítico como la amenaza, realización y escalada de eventos adversos asociados a guerras, terrorismo y tensiones entre estados y actores políticos que afectan el curso pacífico de las relaciones internacionales.

Es importante entender que esta definición contempla el riesgo geopolítico con tres fases: Amenaza, realización y escalada.

La fase de amenaza se entiende como la fase inicial de todo conflicto, cuando existe un posible riesgo sobre el país o entidad observada. Seguidamente encontramos la fase de realización, que se produce cuando el evento ocurre y finalmente la fase de escalada, que se produce al intensificar o extender dicho conflicto o evento.

Para entenderlo más fácilmente, un país podría movilizar tropas en su frontera (amenaza), posteriormente protagonizar un altercado como un ataque o invasión (realización) y finalmente causar desde una guerra abierta hasta una clausura total de la frontera (escalada).

Cada fase de este evento puede tener ciertas respuestas específicas en el mercado según el tipo de conflicto, pues la situación que enfrentan es parecida en esencia y solo cambian los implicados. El hecho de que estas fases sean identificables y generen respuestas diferenciadas y específicas sugiere que un modelo capaz de generalizar correctamente, detectar y clasificar estas fases podría anticipar dichas respuestas

El índice GPR (Geopolitical Risk), también de Caldara e Iacoviello, mide la tensión geopolítica y se monitorea desde 1985. GPR utiliza 10 periódicos de referencia internacional, contando el número de artículos de esos periódicos que mencionan eventos geopolíticos en base a ciertas palabras para conseguir un proceso objetivo y automatizable. Aún siendo algo sencillo, los picos de este índice coinciden con eventos geopolíticos conocidos desde la guerra del golfo hasta la guerra de Rusia y Ucrania.

Entendemos qué son los sucesos geopolíticos, cómo se miden y que afectan directamente a los mercados, pero ¿cómo lo hacen?, ¿Cómo se transmite al mercado? De nuevo, Caldara e Iacoviello (2022), explican la existencia de ciertos canales principales en los que el sentimiento de una situación geopolítica se traduce a los números: La incertidumbre, los precios de la energía y materias primas, el comercio internacional, los flujos de capital y el sentimiento inversor entre otros.

Según Frank H. Knight (1921), la incertidumbre es aquella situación en la que es imposible determinar la probabilidad de que ocurra un evento, a diferencia del riesgo, donde las probabilidades sí son medibles. Es uno de los canales más directos, y ante ella los inversores tienden a retirar dinero de activos arriesgados y moverlo a activos refugio clásicos como el oro o los bonos gubernamentales.

Por otro lado, muchos conflictos geopolíticos se dan en zonas o por razones relacionadas con la energía y demás combustibles, materia prima indispensable para el funcionamiento general de un país. Guerras, sanciones, aranceles o cambios significativos en el precio pueden tener un fuerte impacto en el mercado.

Estas sanciones o aranceles pueden deberse al comercio internacional, otro de los canales más directos ya que pueden reducir el volumen de negocio de las empresas afectadas, impactando en sus ingresos y por tanto en su valoración.

Cuando un país o región se percibe como geopolíticamente inestable, el capital invertido en esa zona tiende a desplazarse hacia mercados considerados más seguros, ya que los flujos de capital buscan siempre localizaciones seguras para asegurar el patrimonio invertido y por ello es un canal más en el que se traduce un suceso geopolítico.

Por último, y relacionado con todos los demás canales, tenemos el sentimiento del inversor, la percepción de un mercado por parte de los inversores, ya sea real o no, impacta directamente en la dirección y el volumen de las operaciones del mercado.

2.1.3 Bases de datos de eventos geopolíticos

Una base de datos de eventos codificados representa, clasifica y almacena los sucesos que ocurren en un tiempo o lugar determinados a partir de información no estructurada.

GDELT (Global Database of Events, Language, and Tone) es una base de datos abierta y gratuita creada por Kalev Leetaru y Philip Schrodt que monitoriza medios de comunicación de todo el mundo en más de 100 idiomas y extrae de forma automatizada los eventos que se mencionan. La plataforma publica dos versiones que conviven en el tiempo: GDELT 1.0, con cobertura desde 1979 y cadencia diaria (un fichero por jornada), y GDELT 2.0, con cobertura desde febrero de 2015 y cadencia de 15 minutos. Este trabajo utiliza la versión 1.0 por las razones que se detallan en §4.1.

GDELT tiene dos partes principales: la *Event Database* y el *Global Knowledge Graph* (GKG):

La Event Database registra eventos individuales. Cada evento tiene 58 campos que incluyen actores implicados, lugar, tiempo y tono mediático. El sistema de codificación usado es CAMEO (Gerner et al., 2002), que es un framework de codificación creado en la Universidad de Kansas que asigna un código numérico a cada tipo de interacción entre actores.

Los códigos CAMEO se organizan en tres niveles anidados de granularidad: EventRootCode con las 20 grandes categorías de comportamiento, EventBaseCode que subdivide cada raíz en subtipos, y EventCode con el detalle fino. Además, CAMEO agrupa el conjunto en cuatro categorías de alto nivel llamadas QuadClass —cooperación verbal, cooperación material, conflicto verbal, conflicto material— que se utilizarán en §4.2.4 para tipificar las aristas del grafo.

Algunas variables de las más relevantes son:

1. GoldsteinScale: Valor numérico de -10 a +10 que mide el impacto teórico de cada tipo de evento en la estabilidad de un país.
2. AvgTone: Tono medio del artículo que reporta el evento. Negativo significa cobertura hostil, positivo significa cobertura favorable.
3. NumMentions / NumSources: Cantidad de veces y de fuentes en que se ha mencionado el evento.
4. Actor1 / Actor2: Actores involucrados, codificados por país, tipo y otros atributos.

Por otro lado tenemos el GKG, que va más allá de los eventos y extrae todas las personas, organizaciones, ubicaciones, temas y emociones mencionadas y los representa en forma de base de datos relacional.

GDELT es una herramienta muy valiosa con muchas ventajas, pero también tiene limitaciones que debemos conocer, entre ellas, la precisión limitada, la redundancia y la evolución no uniforme de la cobertura a lo largo del tiempo.

La precisión limitada se refiere a que al ser un proceso automatizado, existen errores en actores, categorización u otros tipos. En consonancia con la precisión limitada, también existe una cierta redundancia en los eventos que ocurren, ya que cuanto más importante sea uno, más medios hablan de él. Finalmente, la cobertura de GDELT 1.0 no es homogénea en el tiempo: la incorporación de nuevas fuentes durante la primera década de funcionamiento produjo un crecimiento sostenido del volumen de eventos hasta alcanzar un máximo en 2016 (cerca de 2,9 millones de eventos anuales); a partir de ese año, con el relevo asumido por GDELT 2.0 para las fuentes contemporáneas, el volumen anual de 1.0 se estabiliza y decrece de forma leve, llegando a 1,4 millones en 2025. Cualquier estudio que combine tramos anteriores y posteriores a 2016 debe tener en cuenta este cambio de régimen.

Existen otras plataformas alternativas a GDELT como ICEWS o ACLED, pero no cumplen todas estas características, especialmente las de acceso o cobertura. La elección de esta herramienta se debe al conjunto de características que solo GDELT cumple:

1. Acceso libre y gratuito
2. Cobertura global en más de 100 idiomas
3. Cubre todo el espectro de interacciones (cooperación y conflicto, no solo violencia)
4. Cadencia diaria en la versión 1.0 y de 15 minutos en la 2.0, adecuadas para tareas de distinta granularidad temporal.
5. Cobertura temporal desde 1979, la más amplia entre las plataformas comparables.
6. Sus limitaciones (precisión, redundancia) son abordables con preprocesamiento

Los eventos reflejados en GDELT describen interacciones entre actores, que forman de manera natural una red de relaciones. Esta red puede representarse como un grafo, una estructura matemática diseñada para modelar datos relacionales. Para procesar este tipo de estructuras existen las Redes Neuronales de Grafos (GNN, Graph Neural Networks), que constituyen el pilar técnico de este trabajo.

2.1.4 Redes neuronales de grafos

Un grafo se define formalmente como $G = (V, E)$, donde V es un conjunto de vértices o nodos que representan entidades y E es un conjunto de aristas que representan relaciones entre pares de nodos (Wilson, 1996). Este concepto tiene su origen en el trabajo de Euler (1736) sobre el problema de los puentes de Königsberg, considerado el primer teorema de la teoría de grafos.

Los grafos pueden presentar distintas propiedades según cómo se definan sus aristas. En un grafo dirigido, las aristas tienen una dirección concreta: la relación de A hacia B no implica la misma relación de B hacia A. En un grafo no dirigido, la relación es simétrica entre ambos nodos. Los grafos también pueden ser ponderados, donde cada arista lleva asociado un peso numérico que indica la intensidad o magnitud de la relación, o no ponderados, donde simplemente se registra la existencia o ausencia de conexión. Además, tanto los nodos como las aristas pueden incorporar atributos adicionales que enriquecen la información contenida en la estructura, como valores numéricos, categorías o cualquier otra característica relevante para el problema a modelar.

Las redes neuronales clásicas están diseñadas para datos con estructura regular: una imagen es una cuadrícula de píxeles, un texto es una secuencia de palabras, una serie temporal es una secuencia de valores. Pero un grafo no tiene estructura regular, cada nodo puede tener un número diferente de vecinos, no hay orden fijo ni cuadrícula. Las GNN surgen para resolver este problema.

El mecanismo fundamental de las GNN es el *message passing* o paso de mensajes. Cada nodo del grafo parte con una representación numérica propia basada en sus atributos. En

cada iteración, cada nodo recoge la información de los nodos con los que está conectado, la agrega y actualiza su propia representación combinando lo que tenía con lo que ha recibido. Este proceso se repite en capas sucesivas: con una capa cada nodo conoce a sus vecinos directos, con dos capas conoce a los vecinos de sus vecinos, propagando así la información a lo largo de toda la estructura del grafo. Al final del proceso, la representación de cada nodo incorpora no solo sus propios atributos sino también la información de su entorno relacional, y a partir de estas representaciones individuales se puede generar una representación global del grafo que capture el estado general del sistema modelado.

2.1.5 Síntesis

A lo largo del desarrollo del marco teórico se han presentado los fundamentos sobre los que se sustenta este trabajo. Los mercados financieros forman sistemas complejos cuya predicción se ha abordado mediante técnicas cada vez más sofisticadas, desde los modelos estadísticos clásicos hasta las arquitecturas de deep learning actuales. Entre los múltiples factores externos que influyen en el comportamiento de estos mercados, el riesgo geopolítico se ha demostrado como uno de los más relevantes, con canales de transmisión documentados que van desde la incertidumbre hasta los flujos de capital. La existencia de bases de datos como GDELT, capaces de registrar de forma estructurada y masiva los eventos geopolíticos a escala global, abre la posibilidad de integrar esta información en modelos predictivos. Y las redes neuronales de grafos, diseñadas específicamente para procesar datos relacionales, ofrecen el marco técnico adecuado para explotar la estructura natural de red que presentan las interacciones entre actores geopolíticos.

2.2. Estado del arte

En este capítulo se hará el análisis de las principales líneas de investigaciones relacionadas con la predicción de mercados en base a eventos geopolíticos. En específico, se comprobará si ya ha sido aplicado ML para investigar si hay correlación entre eventos y la predicción de

mercados, usando como fuente de datos GDELT u otros tipos de fuentes de información. Posteriormente, se comprobará si ya han aplicado GNN en el ámbito financiero.

2.2.1 Machine learning aplicado al riesgo geopolítico

Niu, Wang & Zhang (2023), descomponen el sistema de GPR, para no tratar este índice como un único número, sino que busca distinguir el tipo de evento y las usan como variables de entrada en varios modelos de ML para predecir la volatilidad en el S&P500. Para ello aplicaron SHAP, una técnica que permite ver qué variables pesan más a la hora de hacer predicciones. Esto sirve para explicar el motivo de la predicción y no únicamente su resultado.

Los resultados que se encontraron es que las movilizaciones militares y la guerra son las categorías que más afectan a la volatilidad y que la implementación de ML supera la predicción de los sistemas clásicos. Pero este estudio sigue teniendo la prensa como fuente de datos y no utiliza eventos estructurados como podría ser el GDELT.

Con este enfoque, *Plakandaras, Gupta & Wong (2019)* analizan el riesgo a nivel global,, centrándose en países emergentes, en vez de centrar totalmente su atención a los Estados Unidos. Para ello, analizaron 14 países por separado usando SVR (Support Vector Regression), para predecir cuatro activos: el oro, el petróleo, tipos de cambio e índices bursátiles. Para ello, se basaron en datos de un mes a dos años en el pasado. Las conclusiones que alcanzaron fueron que el riesgo en países emergentes tiene impacto a nivel regional y mostrando muy poca fuerza en la volatilidad a nivel global. A excepción del oro, demostrando que tiene un papel más centrado en ser un activo refugio, es decir, una inversión diseñada para preservar el capital.

Los trabajos revisados confirman que el riesgo geopolítico tiene capacidad predictiva sobre los mercados financieros, aunque todos muestran limitaciones a la hora de escoger fuentes de datos o utilizar modelos de ML que no capturan las relaciones entre los países, poniendo los esfuerzos en predecir volatilidad . El presente trabajo busca superar las limitaciones usando GDELT como fuente de datos estructurados.

2.2.2 GDELT como fuente de datos para predicción financiera

El uso de GDELT ya ha sido utilizado con anterioridad como fuente de datos principal para capturar la frecuencia de eventos geopolíticos. El trabajo de Fallahi (2017), tesis de máster, lo utilizó junto con SVM, que es muy utilizado para tareas de clasificación y regresión. En el caso de los mercados financieros, es útil para manejar grandes conjuntos de datos y relaciones, encontrando el hiperplano que ajuste los datos en diversas clases, como si el precio de una acción subirá o bajará.

Otros trabajos como el de Consoli et al. (2020), usaron modelos de Gradient Boosting junto a GDELT como fuente de datos, que extraen indicadores de inversión centrado en Italia, para compararlos con la prima de riesgo alemana. Este tipo de modelos aprovecha la combinación múltiples árboles de decisión para mejorar la precisión predictiva y reducir el *overfitting*, aunque presentan un mayor coste computacional durante el entrenamiento.

La investigación más reciente es la de Myers et al. (2025) que desarrolló un framework basado en ontología para construir *knowledge graphs* desde GDELT, aprovechando la estructura de datos que devuelve a diario esa fuente de información. El mayor problema identificado, es la transformación de la base de datos a un grafo utilizable. Este proyecto está centrado en LLMs que capturen eventos para luego poder ser consultados de forma pregunta-respuesta, aunque a veces devuelve resúmenes que carecen de consistencia.

Esta es una aproximación parecida al planteamiento de este proyecto, ya que convierte el GDELT en una estructura de grafo, aunque no lo utiliza para la predicción financiera.

2.2.3 GNN en predicción bursátil

Según una revisión reciente del campo, el mercado bursátil debe de tratarse como una red y no como una entidad singular, ya que el impacto de un evento externo afecta a un conjunto de empresas, que se propaga a otras relacionadas con ella (porque están en el mismo sector o porque tienen una cadena de suministro que las une). A este fenómeno los autores lo

nombraron como *momentum spillover* (Patel, Jariwala & Chattopadhyay, 2025). A partir del análisis de estudios existentes, identificaron tres métodos para la creación de los grafos, con sus diferentes relaciones:

- El primero de ellos calcula la correlación histórica de dos acciones, con el coeficiente Pearson, y si superan un umbral de correlación se crea una arista entre ellas. Por ejemplo, si Apple y Microsoft tienden a subir y bajar juntas en un periodo de tiempo, estarán conectadas. Esto permite analizar las acciones y comprobar su correlación. Esto únicamente tiene en cuenta el precio de las acciones, pero no investiga si hay fenómenos externos que están teniendo un impacto en el precio. Si hay una declaración de guerra que hace que bajen los precios de las acciones, el grafo no se verá reflejado hasta que los precios lleven un tiempo bajando juntos, pero nunca se sabrá que ha podido generar esta fluctuación.
- El segundo método es mediante el *knowledge graphs*. En este, los grafos no se definen por precios, sino por conexiones de diferentes empresas en el mundo real, ya sea porque son proveedores, competidores o cadenas de suministro (Hogan et al., 2021). Se extrae la información de bases como WikiData (Vrandečić & Krötzsch, 2014). El problema de este método es que las relaciones son estáticas y nunca se sabe si ha habido cambios en alguno de los diferentes apartados. Por ejemplo, si una empresa cambia de proveedor para generar sus productos, el grafo no tendrá constancia de este cambio. Así que necesita una comprobación humana que vaya revisando si han habido modificaciones en las relaciones de los grafos.
- Y por último, está el grafo automático, que busca automáticamente las relaciones que unen las empresas. Utiliza un autoencoder variacional que comprime los datos de cada empresa en un vector de características, que captura patrones de volatilidad, respuesta a eventos, cambios en la empresa y, posteriormente, comparar estos vectores para decir con que peso las conecta. Si hay dos empresas que tienen datos parecidos, aunque no sean del mismo sector, el modelo las conecta.

Esto permite encontrar correlaciones de empresas que en principio no tienen nada que ver pero que se comportan de forma parecida ante un momento de incertidumbre geopolítica. Esto permitiría añadir una capa de análisis que el humano por sí mismo, nunca podría encontrar. Con esto, encontraron dos problemas en este sistema, y es que los gestores de

riesgo necesitan entender el por qué de estos comportamientos y el motivo de que el agente tome las acciones que toma. El segundo, es que puede ser que dos empresas se vean relacionadas durante el periodo de entrenamiento del modelo, pero al llevarla en la práctica, se encuentra que no tienen nada que ver entre ellas. Esto puede generar predicciones erróneas a la larga.

Aunque se habían hecho pruebas, habían demasiadas incertidumbres sobre el funcionamiento. Para abordar estas limitaciones, Kim et al. (2019) propusieron HATS (*Hierarchical Graph Attention Network for Stock Movement Prediction*), un modelo diseñado específicamente para la predicción bursátil mediante grafos. Los autores concluyeron que había dos problemas. El primero es que la calidad de la información recogida para la creación de los mismos no estaba siendo tratada correctamente, haciendo que las relaciones y valores que se creaban eran poco exactos. El segundo es que no se estudiaba los mercados completos, sino como agentes individuales.

Para resolverlo, HATS aplica un mecanismo jerárquico de dos niveles. Primero pondera la importancia vecina de cada empresa dentro de un mismo tipo de relación y luego decide el tipo de relación más adecuada para cada momento. Se dieron cuenta que era muy importante tener datos y relaciones adecuadas, ya que incorporar relaciones irrelevantes empeoraba el rendimiento del modelo.

Evaluable sobre las empresas del S&P500, HATS trató el índice como un grafo completo y cada nodo era una empresa. Mediante *graph pooling*, condensaron toda la información en un único vector para predecir si el índice subiría, bajaría o se mantendría estable. Los resultados mostraron un Sharpe ratio un 19,8% superior y un F1 un 3% mayor respecto a las baselines existentes.

Sin embargo, el grafo de HATS seguía siendo estático, las relaciones entre las empresas no cambiaban con el tiempo. Chen et al. (2023) identificaron éste como un problema en todos los modelos anteriores, un *knowledge graph* predefinido no puede analizar si el mercado evoluciona o ha sufrido cambios, y tampoco es capaz de distinguir la diferencia de dos eventos, que parecen similares pero son totalmente diferentes. Por ejemplo, el abandono de un directivo de una empresa pequeña y la dimisión de Steve Jobs en Apple son el mismo tipo de noticia y el titular será muy parecido, pero el impacto que tienen en la industria son muy distintos.

Para resolverlo, propusieron usar ChatGPT para construir un grafo dinámico utilizando noticias financieras. A diario, el agente analizaba las noticias de ese día e infería para comprobar qué empresas tenían relaciones entre sí, generando un grafo nuevo y actualizado diariamente. Es importante remarcar que este grafo añade información a diario pero las relaciones permanecen estables en el tiempo.

Su funcionamiento es que un GNN procesa ese grafo para generar una representaciones vectoriales por empresa, que luego se combina con un LSTM para predecir el posible movimiento del día siguiente. Evaluando sobre 30 empresas, el modelo superó todos los baselines con una mejora mínima del 1.8% en F1, y las carteras que la utilizaron como herramienta de predicción tuvieron mayor retorno anual y menor volatilidad.

Este trabajo es relevante porque demuestra que utilizar fuentes de información muestran una mejora en el sistema de predicción del grafo. Aunque esta herramienta tiene una limitación y es que únicamente hace una búsqueda de noticias de naturaleza corporativa, dejando de lado eventos geopolíticos entre países. Ese es el espacio mejorable mediante GDELT, para añadir información de forma más global sin una limitación a noticias empresariales, como por ejemplo, eventos entre países, tensiones militares o conflictos que impactan al mercado antes de que aparezcan reflejados en noticias de naturaleza corporativa.

Todos los modelos nombrados con anterioridad comparten una deficiencia común, todas las relaciones entre empresas son estables en el tiempo, y no tienen en cuenta que hay variaciones en el mercado que pueden variar según el ciclo económico, eventos externos o rotaciones de mercado. Esto hace que los modelos queden obsoletos con el tiempo.

FSTGAT propuso una mejora para resolver esta limitación. En lugar de utilizar redes LSTM para capturar datos, usan convolución causal (van den Oord et al., 2016) , una técnica que garantiza que los datos són siempre del pasado y nunca puede usar datos a futuro. Así no puede entrenarse con datos que en la práctica no estarían disponibles en el momento de la predicción. También innovó utilizando una versión mejorada del GAT (Veličković et al., 2018) , que incorpora más información sobre el mercado y permite que haya modificaciones en las aristas ya implementadas. Si por ejemplo hay una correlación que desaparece, las aristas se actualizan.

La última implementación es la agrupación de empresas por sector, haciendo que el modelo aprenda de forma simultánea las relaciones dentro del grupo y entre grupos distintos. Esto demostró más eficiencia y precisión que tratar todas las empresas como un único conjunto plano.

Los resultados demuestran que en escenarios de gran volatilidad, un modelo GNN reduce el error de predicción entre un 45% y un 69%. Este dato confirma que añadir la capa de GDELT, debería amplificar las ventajas que aporta el GNN en escenarios de incertidumbre.

Los métodos descritos comparten una limitación común, el grafo se construye mediante la información del mercado financiero, pero ninguno de ellos tiene la capacidad para incorporar información externa como eventos geopolíticos. El enfoque propuesto para este trabajo, busca incorporar estos datos, para que el grafo se construya a partir de eventos extraídos de GDELT, representando interacciones entre países que permitan anticipar fluctuaciones de mercado antes de que la información quede imbuida en los datos financieros.

2.2.4 Grafos temporales y dinámicos

A la hora de escoger el tipo de grafo, es muy importante analizar qué tipos se pueden usar y cuáles son los beneficios que pueden aportar al proyecto.

Los grafos estáticos tienen aristas fijas y las relaciones entre los nodos no se modifican con el tiempo. Es el que usaba HATS y otros modelos analizados, el problema de estos es que no tienen en cuenta que las relaciones pueden evolucionar, un conflicto puede crear o destruir relaciones entre países, haciendo que el grafo deje de tener sentido.

Los grafos dinámicos discretos generan un grafo nuevo por cada periodo de tiempo, por ejemplo cada día. Cada espacio de tiempo captura el estado de relación en ese momento. Es un enfoque más acertado a la hora de analizar eventos del GDELT, ya que tiene un sistema de refresco de información que va capturando dinámicamente el estado global de un periodo de tiempo específico, y permite predecir de forma más precisa eventos en el siguiente periodo.

Los grafos dinámicos continuos permiten incorporar información en tiempo real, actualizando constantemente las relaciones entre nodos. Sin embargo, este enfoque incrementa mucho el flujo de datos y suele aplicarse en escenarios que evolucionan de forma continua. En la predicción diaria quizás es más adecuado utilizar grafos dinámicos discretos basados en momentos temporales.

2.3.Conclusiones

En este capítulo se ha confirmado que el riesgo geopolítico tiene capacidad predictiva sobre mercados financieros gracias a las investigaciones de Caldara & Iacoviello (2022), Niu et al. (2023) y Plakandaras, Gupta & Wong (2019). Aunque todos utilizan fuentes de prensa como datos, aplicando modelos de ML incapaces de relacionar los eventos y los países.

También se ha demostrado con las investigaciones de Fallahi (2017), Consoli et al. (2020) que GDELT es una fuente de datos válida a la hora de analizar grandes conjuntos de datos, aunque su transformación a grafos es costosa y complicada.

Por último, se ha demostrado con HATS (Kim et al., 2019), Chen et al. (2023) y FSTGAT (Wei et al., 2025) que modelar el mercado como un grafo permite predecir volatilidad y dirección de índices bursátiles. Sin embargo, ninguno de los tres enfoques integra información geopolítica externa: HATS y FSTGAT construyen el grafo con relaciones entre empresas del propio índice, y Chen et al. lo alimenta con noticias corporativas. HATS constituye además el precedente más directo del target elegido en este trabajo —dirección del S&P 500—, aunque su arquitectura difiere en tratar cada empresa como nodo en lugar de cada país. Chen et al., por su parte, procesa el grafo con una GNN y la serie temporal del mercado con una LSTM posterior, lo que equivale conceptualmente a una arquitectura de late fusion en la que el grafo y el target nunca interactúan dentro del mismo modelo.

De la revisión de estas tres líneas, emergen cuatro cuestiones que no se han resuelto de forma simultánea. Que son las siguientes:

1. Combinación de GDELT con una GNN como fuente de datos externa al mercado.
2. Construcción de un grafo centrado en los países como actores geopolíticos, donde los eventos son las aristas.
3. Predicción del movimiento de un índice a partir de información geopolítica sin depender exclusivamente de un historial de precios.
4. Integración profunda del target financiero dentro del propio grafo, evitando la separación en dos ramas típica de late fusion.

3. Objetivos concretos y metodología de trabajo

3.1. Objetivo general

Diseñar, implementar y evaluar un modelo de predicción de la dirección del S&P 500 basado en redes neuronales de grafos que integre datos de eventos geopolíticos extraídos de GDELT con indicadores del mercado bursátil.

3.2. Objetivos específicos

- Definir y seleccionar un conjunto de periodos históricos geopolíticamente relevantes dentro de GDELT que permitan construir un dataset representativo y manejable para el entrenamiento del modelo.
- Diseñar la representación en grafo de las relaciones entre actores geopolíticos, definiendo nodos, aristas y atributos, y validando el resultado mediante una revisión manual de una muestra representativa.
- Automatizar la predicción diaria del modelo, verificando que sea capaz de generar una señal de inversión antes de la apertura de cada sesión bursátil.
- Implementar la integración de la GNN con los datos históricos del S&P 500 para la predicción triclase, alcanzando un F1-score superior al de un modelo de referencia sin información geopolítica.

OE1. Construir un dataset diario continuo del periodo 2015-2025 a partir de GDELT 1.0, filtrado por un roster fijo de veinte actores geopolíticos y por un umbral de cobertura mediática ($\text{NumMentions} \geq 5$), que sirva como entrada al modelo tras el preprocesamiento descrito en §4.1.

OE2. Diseñar la representación en grafo heterogéneo de las relaciones entre esos actores y el mercado, definiendo nodos, aristas y atributos, y validar el resultado mediante análisis cuantitativos de la distribución de grados, la distribución de eventos por QuadClass y los pares origen-destino dominantes.

OE3. Diseñar un flujo reproducible extremo a extremo, desde la ingesta de GDELT hasta la evaluación, verificando que la construcción del grafo del día t utiliza exclusivamente información disponible antes del cierre del mercado de esa jornada. La cadencia diaria de GDELT 1.0 garantiza esta separación por construcción, y la etiqueta se calcula sobre el retorno cierre-a-cierre entre t y $t+1$.

OE4. Implementar la integración de la GNN con los datos históricos del S&P 500 para la clasificación triclase (bajada, neutralidad, subida) y superar en F1 macro a los modelos de referencia efectivamente contruidos: baseline trivial de clase mayoritaria, regresión logística y XGBoost sobre las mismas features del grafo aplanadas. La comparación con un modelo de referencia sin información geopolítica —el que permitiría aislar de forma limpia la aportación específica de modelar la geopolítica como red— queda identificada como línea de trabajo futuro por las razones expuestas en §7.2.

OE5. Profundizar en el conocimiento de las redes neuronales de grafos, un ámbito que despertó interés durante el máster y quedó fuera del alcance de las asignaturas cursadas, aplicándolo a un problema real interdisciplinar en la intersección entre inteligencia artificial, mercados financieros y análisis geopolítico. Esto incluye el estudio y la comparación de variantes heterogéneas (HGT, HeteroGAT, GATv2), la traducción del marco teórico de los procesos de Hawkes y las tres fases del riesgo geopolítico (Caldara e Iacoviello, 2022) a un mecanismo operativo dentro del modelo, y el uso del ecosistema PyTorch Geometric.

OE6. Consolidar buenas prácticas de reproducibilidad experimental durante todo el desarrollo: control de semillas, esquema de validación walk-forward respetuoso con la naturaleza temporal del problema, versionado del código y de los datos, y documentación explícita de las decisiones metodológicas y de sus alternativas descartadas.

3.3. Metodología del trabajo

Para llevar a cabo la consecución de los objetivos planteados, se han establecido una serie de fases que estructuran el desarrollo del trabajo:

Fase 1. Construcción del dataset geopolítico: Selección de periodos históricos relevantes dentro de GDELT, extracción de datos y preprocesamiento.

Fase 2. Construcción del dataset financiero: Obtención de datos históricos del S&P 500 para los mismos periodos seleccionados en la fase anterior. Definición de la variable objetivo: clasificación triclase (subida, bajada, neutralidad) del índice para la siguiente sesión.

Fase 3. Diseño y construcción del grafo geopolítico: Definición de qué entidades constituyen los nodos, qué eventos forman las aristas y qué atributos de GDELT se asignan como características. Generación de snapshots diarios del grafo.

Fase 4. Diseño e implementación del modelo: Evaluación de diferentes arquitecturas de GNN y diseño del mecanismo de fusión entre la información geopolítica del grafo y la información financiera del S&P 500.

Fase 5. Entrenamiento y evaluación: Entrenamiento con los datos históricos seleccionados y evaluación del rendimiento mediante métricas de clasificación como accuracy, F1-score, precisión y recall.

4. Descripción detallada del experimento

Una vez fijados los objetivos y la metodología del capítulo anterior, este capítulo describe cómo se ha realizado el experimento. Desde la recogida y limpieza de datos, hasta un modelo capaz de descubrir antes de la apertura del mercado estadounidense, si el índice va a subir, bajar o permanecer neutro. Para ello se va a construir un grafo heterogéneo que integra la señal geopolítica y la información del mercado que le permite tomar decisiones a corto plazo.

4.1 Filtrado de datos

La fuente de datos que se ha escogido para hacer el proyecto es GDELT 1.0 Events. La elección se ha tomado tras descartar su versión 2.0 y GKG. La decisión se sustenta en dos aspectos:

- Aunque la versión 2.0 ofrece una granularidad de quince minutos, la predicción de este trabajo se emite una vez por sesión bursátil, por lo que todo el contenido se tendría que reagrupar a escala diaria. La cadencia de 1.0 se ajusta a esa unidad de decisión y reduce el coste de ingesta: 3.998 ficheros frente a unos 381.000 para el mismo periodo.
- GKG y 2.0 tienen noticias desde el 2013 y 2015, mientras que su versión 1.0 tiene más de 20 años de noticias.

Cada fichero diario en formato csv consta de un volumen aproximado de 100.000 a 300.000 eventos diarios.

Para fechas anteriores al 1 de abril de 2013, empaqueta los CSV en ficheros mensuales y cuando llega al 2005 son anuales.

GDELT 1.0 define un esquema fijo de 58 columnas sin cabecera. Para que lo cargue con tipos correctos, se reproduce la lista de nombres y se identifican las siguientes columnas numéricas:

- `GoldsteinScale`: Puntuación del posible impacto de un evento sobre la estabilidad de un país. Es una escala fija de -10 (máximo conflicto) a +10 (máximo beneficio).
- `NumMentions`: Veces que se nombra el evento durante el día.

- `NumSources`: Número de fuentes de información distinta que informan del evento.
- `NumArticles`: Número de artículos distintos que han nombrado la noticia.
- `AvgTone`: Tono medio de los documentos que mencionan el evento.

El resto se conserva como cadena para mantener compatibilidad con los códigos CAMEO (Conflict and Mediation Event Observations) y FIPS (Federal Information Processing Standards), que aunque sean numéricos en apariencia (01,02...) deben tratarse como categóricos.

GDELT codifica los eventos mediante el sistema CAMEO , que define tres niveles de granularidad:

- `EventRootCode`: grandes categorías de comportamiento, ordenadas de máxima cooperación a máximo conflicto.
- `EventBaseCode`: subdivide cada raíz en subtipos.
- `EventCode`: detalle fino sobre el subtipo.

Para el desarrollo del proceso de tratamiento de datos, se opta por trabajar con un único día de datos como muestra

Es necesario realizar una limpieza inicial para intentar minimizar la cantidad de repetidos que hay. Por ejemplo, una noticia que se ha actualizado diariamente o varios medios de comunicación que han cubierto lo mismo. Para ello, lo primero que se realizará es una normalización de la URL, que es lo único que aporta información de los hechos que han ocurrido. Se tienen que cumplir las siguiente reglas:

- Conversión a minúsculas (*Example.com* y *example.com* apuntan al mismo recurso).
- Eliminación de los puertos por defecto :80 y :443.
- Eliminación de parámetros de traza(*?utm_source=...*, *?ref=...*), que no afectan al contenido.
- Eliminación de fragmentos (*#section*), que tampoco modifican el recurso.
- Supresión de la barra final de una URL, que señala que está apuntando a un directorio en lugar de un archivo.

Los resultados son los siguientes:

- Filas antes: 118 201

- Descartadas por URL no interpretable: 0
- Filas tras normalización: 118 201
- URLs únicas: 24 412

Es decir, cada artículo genera de media casi cinco filas en GDEL, y solo poco más de una cuarta parte aparece una única vez.

Las URLs más utilizadas han sido las siguientes: https://targetednews.com/pr_disp.php se ha repetido 158 veces, https://freerepublic.com/tag/*/ 125 y <https://ismatimes.com/gttci-ethiopian-coffee-evening-farewell> 118x.

Las dos más repetidas (158 y 125 ocurrencias) corresponden a URLs genéricas sin contenido específico, ya que al investigarlas, muestran webs de que no se ha encontrado noticias o menús principales. Hay que desecharlas también para que no entren en el recuento de las métricas dando unos eventos que no tienen ningún sentido.

Para detectar contenido equivalente y para los pasos de las representaciones vectoriales y LDA (Latent Dirichlet Allocation) posteriores se construye, por evento, un texto sintético a partir de tres fuentes complementarias:

1. **Texto identificador de la URL:** En muchas cabeceras actuales el titular va embebido en la URL (*/news /elon -musk-jets-off-to-china, /politics /israel- lebanon- ceasefire-extended*). Se extraen los *tokens* de la ruta, se descartan los de longitud inferior a tres caracteres, los que contienen dígitos (típicos de identificadores), los hexadecimales (UUIDs) y un conjunto cerrado de stopwords específicas de URLs (*news, article, html, index, ...*).
2. **Metadatos estructurados del propio evento:** *Actor1Name, Actor2Name* y *ActionGeo_FullName*, todos en minúsculas.
3. **Etiquetas textuales de la codificación CAMEO:** descripción del *EventRootCode* (*appeal, protest, fight, ...*) y del *QuadClass* (*verbal cooperation, material conflict, ...*). Aportan el "qué tipo de evento" en lenguaje natural.

Tras aplicar el filtro que descarta las URLs cuyo slug contiene menos de tres tokens, se parte de 118 201 filas y se conservan 107 248 (90,7 %), descartándose 10 953 (9,3 %) por no disponer de texto suficiente para el análisis.

El texto sintético obtenido a partir de cada URL presenta una longitud media de 18 tokens (mediana de 18), con un mínimo de 7 y un máximo de 43. Se trata, por tanto, de fragmentos breves y homogéneos, adecuados para el procesamiento posterior.

A modo ilustrativo, dos filas tomadas al azar muestran cómo cada URL se reduce a una secuencia compacta de palabras clave que conserva los actores, la acción y el tipo de evento:

- Una noticia sobre la cancelación de un despliegue militar en Polonia se transforma en "your military army leaders hot seat over poland deployment cancellation european publication iran reject verbal conflict".
- Una noticia sobre la prórroga del alto el fuego entre Israel y Líbano queda como "israel lebanon ceasefire extended days israeli washington district of columbia united states reject verbal conflict".

En ambos casos, el texto resultante captura la esencia geopolítica del evento (actores implicados, naturaleza de la acción y clasificación del conflicto) en una representación reducida y normalizada.

El filtro descarta el 9.3 % de las filas(10 953), exactamente las que tenían URL genérica sin titular embebido. El texto resultante tiene una mediana de 18 tokens, suficiente para alimentar las representaciones vectoriales y para un LDA de baja resolución temática.

El conteo por URL detecta exactamente la misma URL repetida, pero no captura el caso de mayor interés para este trabajo: un mismo evento cubierto por medios distintos, con URLs diferentes pero contenido equivalente. Para abordar este caso se proyectan los textos sintéticos a un espacio vectorial denso mediante representaciones vectoriales, y se agrupan los vectores cercanos por similitud coseno.


Granularidad: Se calcula un representaciones vectoriales por URL única. Esta decisión se basa en que todas las filas asociadas a una misma URL comparten el slug, por lo que sus textos sintéticos son prácticamente idénticos. La reducción es de aproximadamente 107 248 filas a 22 572 URLs únicas.

Modelo: Se utiliza `sentence-transformers/all-MiniLM-L6-v2`.

Algoritmo de agrupamiento: Se construye un grafo dirigido de k-vecinos más próximos sobre las representaciones vectoriales (k = 15, métrica coseno). Se filtran las aristas cuya similitud

coseno sea inferior a 0.80, y se calculan las componentes conexas del grafo resultante. Cada componente es un grupo de noticias relacionadas.

Resultado: Sobre el fichero analizado, los 22 572 puntos se agrupan en 19 423 grupos, de los cuales el 94.4 % son singletons (un único punto sin vecinos suficientemente próximos) y el 5.6 % son grupos de dos o más. El grupo más grande contiene 318 URLs. El tamaño medio de grupo es 1.16.



Top 3 grupos por tamaño:

1. Grupo 130 (318 URLs):

<http://www.bgnes.com/politics/trump-warns-taiwan-not-to-move-toward-independence>

texto: trump warns taiwan not move toward independence taiwan beijing, beijing, china threaten verbal conflict

2. Grupo 143 (107 URLs):

<https://13wham.com/news/local/suspected-hantavirus-case-in-ontario-county-involves-geneva-high-school-student>

texto: suspected hantavirus case ontario county involves geneva high school student


3. Grupo137 (93 URLs):

<http://www.heraldglobe.com/news/.../amid-spiralling-relations-cuban-government-meets-cia>

texto: amid spiralling relations cuban government meets cia director ratcliffe havana

El umbral coseno de 0.80 elegido produce grupos de naturaleza temática más que de "misma noticia exacta". El mayor grupo, al examinarlo, agrupa noticias diplomáticas heterogéneas (advertencias EE.UU.-Taiwán, prórroga del alto el fuego Israel-Líbano, etc.) que comparten vocabulario y estructura (*"threaten"*, *"verbal conflict"*, nombres de países en tensión). Los grupos de tamaño intermedio (decenas de URLs), en cambio, sí corresponden a un único evento cubierto por muchos medios: el grupo de 85 URLs sobre el juicio a Harvey Weinstein o el de 107 URLs sobre el brote de hantavirus tras un crucero. Para una deduplicación estricta tipo "mismo artículo reescrito" habría que subir el umbral, aceptando que muchas reescrituras se quedan sin agrupar.

Para poder comprobar cómo ha funcionado, se ha seleccionado tres días diferentes y se ha puesto a prueba para comprobar si ha funcionado correctamente o si los valores que se han eliminado han cambiado mucho:





El porcentaje de descarte por filtro de slug, el factor de inflación y el porcentaje de singletons del agrupamiento varían dentro de márgenes de unas pocas décimas.

Pero sigue habiendo mucho contenido para añadirlo al grafo. Hay que reducir mucho más este contenido, ya que si sumamos los tres días de ejemplo, aparece que hay 288.925 filas y 51.294 grupos semánticos, lo cuál son datos muy elevados. Para ello se van a aplicar dos filtros:

- Concurrencia de fenómenos: Conservar noticias que mínimo aparezcan en X medios

distintos. Si varios medios cubren el mismo evento, es posible reducir el ruido local (noticias que han ocurrido en un estado de Estados Unidos pero que no tiene impacto en el resto de país).

- Relevancia geopolítica: Conservar solo eventos en los que haya al menos un actor de gran importancia.



Se han hecho pruebas para ver cuál es el umbral que se va a utilizar para filtrar y se ha decidido que 5 es un buen número ya que no deja de lado muchas posibles noticias que tienen potencial interés para el grafo.


Tras la limpieza y reducción del contenido, se ha aplicado un LDA sobre el corpus de textos. El objetivo es complementar el grupo y descubrir temas dentro de estos textos, para poder agruparlos. Como no tenemos textos complejos, sino URL, el LDA detecta patrones de palabras.

Los tópicos no representan temas argumentales, sino patrones de concurrencia de palabras, que pueden ser desde países, ciudades o eventos. La siguiente tabla recoge 5 tópicos resultantes junto con el número de documentos asignados a cada uno.

ID	Document	Palabras representativas
1	3,306	israel general media bank chief west gaza lebanon british arab israeli emirates
2	3,794	india delhi new pradesh minist governor senate colorado federal global michigan ece
3	2,003	business university day cuba administration oklahoma singapore travel kansas arrest tax hawaii

4	4,434	states united columbia district washington government house illinois american spain home pennsylvania
5	2,865	france italy general nation philippines college death malaysia worker manila karnataka meeting

Se asigna a cada noticia el tema de su documento representativo. Esto cuantifica la composición temática del corpus filtrado.



4.2 Decisiones técnicas

Una vez establecidas las fuentes de datos y el filtrado correspondiente en el apartado anterior, el siguiente paso consiste en definir cómo se modela el problema desde un punto de vista arquitectural. Esta sección recoge las decisiones técnicas tomadas durante el diseño del sistema, junto con las alternativas que se valoraron y las razones que motivaron descartarlas. El proceso no ha sido lineal: varias de estas decisiones se discutieron en múltiples ocasiones y algunas se reformularon a medida que comprendíamos mejor las implicaciones de cada opción.

4.2.1 Modelado temporal del grafo

El primer aspecto a resolver fue cómo incorporar la dimensión temporal al grafo. Los eventos geopolíticos no son fenómenos aislados que aparecen y desaparecen en un único día: una

tensión entre dos países puede gestarse durante semanas, manifestarse en un evento concreto y prolongar sus efectos en el tiempo. Cualquier diseño que ignorase esta dinámica capturaría el problema de forma incompleta.

En el campo de las Temporal Graph Neural Networks (TGNN) coexisten tres familias principales. La primera es la de los grafos dinámicos discretos (Discrete-Time Dynamic Graphs, DTDG), donde el tiempo se divide en intervalos y se construye un grafo independiente para cada uno de ellos. La temporalidad se modela en una segunda fase mediante una red recurrente que procesa la secuencia de representaciones vectoriales producida por la GNN. Este es el enfoque que utiliza, por ejemplo, Chen et al. (2023). Su principal limitación es que cada grafo "olvida" estructuralmente al anterior, y la memoria temporal queda relegada a la red recurrente posterior, fuera del propio grafo.

La segunda familia, los grafos continuos (Continuous-Time Dynamic Graphs, CTDG), procesa cada evento con su timestamp exacto y mantiene un estado de memoria por nodo que se actualiza con cada nuevo evento. Si se hubiera elegido GDELT 2.0 como fuente de información, descartado en el apartado 4.1, tendría sentido haber usado este enfoque. Así que no es que este tipo de grafos sean demasiado granulares y complejos, sino que no disponemos de los datos necesarios para su funcionamiento, ya que la versión 1.0 registra la fecha pero sin tener en cuenta la hora exacta, de modo que todos los eventos de una misma jornada comparten la misma marca de tiempo. Aun si tuviéramos estos datos, la complejidad adicional no compensaría, ya que se incrementarían los costes computacionales y de implementación sin saber si tendría un beneficio directo para el experimento.

La tercera opción, y la que finalmente adoptamos, consiste en mantener un único grafo persistente cuyas aristas se refuerzan con cada nuevo evento y decaen exponencialmente con el tiempo en ausencia de actividad. Esta formulación, inspirada en los procesos de Hawkes (Hawkes, 1971), captura de forma natural la idea de que una relación geopolítica activa hoy sigue siendo relevante durante los días siguientes, aunque cada vez con menos peso, hasta que nuevos eventos la revitalizan o desaparece. La elección de este enfoque no fue solo pragmática sino también teórica: encaja directamente con las tres fases del riesgo geopolítico (amenaza, realización y escalada) descritas por Caldara e Iacoviello (2022) en el marco teórico de este trabajo. Una arista entre dos países puede ir acumulando peso durante la fase de amenaza, dispararse en la realización y mantenerse alta durante la

escalada, todo ello sin que el modelo necesite tratar cada día como un evento independiente.

Este mecanismo no se aplica igual en todas las aristas, ya que los eventos no dejan exactamente el mismo rastro sobre el mercado. El ritmo al que decae cada arista depende de la categoría CAMEO del evento que la alimenta. Por ejemplo, un ataque militar tiene más presencia en el tiempo que un discurso.

QuadClass	Multiplicador	λ efectiva	Vida media
1. Cooperación verbal	1,5	0,1040	6,7 días
2. Cooperación material	1,0	0,0693	10,0 días
3. Conflicto verbal	0,7	0,0485	14,3 días
4. Conflicto material	0,4	0,0277	25,0 días

La vida media base es de diez días, y sobre ella se aplica un multiplicador por categoría que la acorta hasta los 6,7 días en la cooperación verbal y la alarga hasta los 25 en el conflicto material: el rastro de un enfrentamiento armado dura casi cuatro veces más que el de un intercambio de declaraciones. Estos datos se han fijado con anterioridad siguiendo el razonamiento sobre las tres fases del riesgo geopolítico. Por último, los eventos con una antigüedad de sesenta días se descartan del grafo, ya que su peso en ese punto ya es despreciable, por debajo del 2%, pero el conflicto material todavía conserva el 19% de modo que el corte elimina en ese caso una parte apreciable de la memoria que ha ido acumulando.

Adicionalmente, los procesos de Hawkes son un modelo estocástico ampliamente utilizado en finanzas para modelar contagio entre mercados y otras dinámicas de auto-excitación (Bacry et al., 2015) . La conexión con literatura económica refuerza la elección: no se trata de

una fórmula ad hoc, sino de una formulación que tiene precedente y validación en el campo. Conviene precisar que el modelo no ajusta un proceso de Hawkes exacto, ya que no estima la intensidad condicional a partir de los datos, sino que aplica un decaimiento exponencial con unos valores fijados que se han descrito en la Tabla X.

4.2.2 Integración del SP500: SP500 como nodo del grafo

La segunda decisión, y probablemente la más debatida durante el diseño, fue cómo integrar la información del SP500 con la información geopolítica del grafo. Aquí se valoraron tres opciones que representan grados crecientes de integración entre ambas modalidades, y cada una de ellas generó discusiones específicas que conviene recoger.

La primera opción, late fusion o fusión tardía, consiste en mantener dos ramas paralelas e independientes durante todo el procesamiento. Una GNN procesaría el grafo geopolítico produciendo una representación vectorial, una LSTM procesaría las series temporales del SP500 produciendo otra representación vectorial, y ambos se combinarían mediante concatenación justo antes de la capa de clasificación final. Esta arquitectura, conocida también como two-tower architecture, es ampliamente utilizada en problemas multimodales y resulta atractiva por su sencillez. Cada rama puede entrenarse y depurarse de forma independiente, los ablation studies son triviales (basta con eliminar una rama y reentrenar para medir su aportación), y las dos modalidades pueden tener escalas y naturalezas radicalmente distintas sin afectarse entre sí.

Sin embargo, conforme analizábamos esta opción con más detenimiento, fueron emergiendo dudas conceptuales importantes. La más fundamental es que las dos ramas nunca se hablan durante el procesamiento: la GNN procesa exclusivamente el grafo geopolítico, sin saber en ningún momento qué está haciendo el mercado, y la LSTM procesa exclusivamente las series financieras, sin saber en ningún momento qué está pasando geopolíticamente. La interacción entre ambas modalidades queda relegada a una única concatenación final, donde un MLP recibe dos vectores ya cerrados y debe aprender a combinarlos. Esto significa que el modelo solo puede capturar correlaciones tardías y agregadas entre las dos señales, pero pierde por completo las interacciones más finas: por ejemplo, no puede aprender que "una crisis energética rusa afecta especialmente al SP500 cuando el VIX está elevado" o que "un anuncio del Pentágono sobre China impacta de forma distinta según el momento del ciclo de tipos de interés". Estas interacciones cruzadas son precisamente las que más relevantes

resultan para el problema, y la arquitectura de late fusion estructuralmente no puede representarlas.

A esta limitación conceptual se sumó una contradicción aparente con la propia tesis del trabajo. Si la hipótesis central es que la geopolítica contiene señal predictiva sobre los mercados, mantener la GNN procesando exclusivamente información geopolítica, sin que en ningún momento "vea" el estado del mercado, resulta poco coherente con esa narrativa. Un tribunal académico podría legítimamente preguntar por qué se ha elegido una arquitectura tan sofisticada como una GNN para procesar una sola modalidad, cuando la integración real entre las modalidades es la parte que aporta el valor diferencial. Late fusion, en este sentido, desaprovecha la estructura que se ha construido: el grafo geopolítico se queda como un módulo aislado que produce un vector, sin que el resto del sistema interactúe con él en ningún momento del procesamiento.

Por último, considerábamos la ventaja de la modularidad pero también su contraparte. Es cierto que late fusion permite validar cada rama por separado, lo cual es útil durante el desarrollo. Pero esa misma modularidad implica que las dos modalidades operan en "compartimentos estancos", y la decisión de cómo y cuánto pesa cada una recae enteramente sobre la concatenación final, que es un punto del modelo con capacidad expresiva limitada en comparación con todo el procesamiento previo. En definitiva, late fusion es una arquitectura defendible pero conservadora, que probablemente funcionaría como baseline correcto pero que no aprovecharía el potencial completo de modelar el problema como un sistema integrado.

La segunda opción, y la que finalmente elegimos, consiste en integrar el SP500 como un nodo adicional dentro del grafo heterogéneo. En esta arquitectura no hay rama paralela. El SP500 se convierte en un nodo de tipo distinto al de los países, con sus propias features financieras (retornos a distintos horizontes, volatilidad, volumen, indicadores macroeconómicos como el VIX o los tipos de interés), conectado a los nodos país mediante aristas específicas. La predicción de la dirección del mercado emerge de la representación vectoriales final de ese nodo tras el message passing.

La ventaja conceptual de esta arquitectura es que las dos modalidades interactúan en cada iteración del procesamiento. En la primera capa de message passing, el nodo SP500 recibe mensajes de los países conectados, que llevan información geopolítica del día; al mismo

tiempo, los nodos país reciben información del estado del mercado a través de las aristas que les conectan con el SP500. En la segunda capa, las representaciones vectoriales ya enriquecidos se vuelven a propagar, de forma que la representación vectoriales final del SP500 contiene una representación de "estado del mercado dado el contexto geopolítico actual", y las representaciones vectoriales de los países contienen una representación de "situación geopolítica dada la sensibilidad actual del mercado". Esta integración profunda es exactamente la que late fusion no puede capturar.

A esta ventaja conceptual se añaden otras dos. La primera es la interpretabilidad directa: el mecanismo de atención del GATv2 permite, para cada predicción, obtener los coeficientes de atención que el modelo ha asignado a cada arista país-SP500. Esto significa que se puede responder a preguntas como "¿qué países influyeron más en la predicción del 24 de febrero de 2022?" con una respuesta numérica concreta y trazable. Esta propiedad no se ha investigado en el trabajo, ya que está centrado en la evaluación cualitativa del modelo. Extraer los coeficientes de atención en fechas concretas permitiría contrastar si pondera los actores más importantes en diversos espacios de tiempo. Por ejemplo, Ucrania durante la invasión en febrero de 2022. Se trata de un análisis que queda identificado como línea de trabajo futuro en las conclusiones. La segunda ventaja es la diferenciación frente al estado del arte. Chen et al. (2023), que es la referencia más cercana a nuestro trabajo, utiliza un esquema GNN-LSTM separado donde la GNN procesa el grafo y la LSTM procesa la secuencia temporal del mercado de forma posterior. Conceptualmente, esto equivale a una arquitectura de late fusion: el grafo y el target nunca interactúan dentro del mismo modelo. Al integrar el target dentro del grafo, nuestra propuesta se distingue claramente de este enfoque y cierra el segundo de los gaps identificados en el estado del arte, relativo a la centralidad de las relaciones entre países en lugar de entre empresas.

La tercera opción, más ambiciosa, consistiría en sustituir el nodo SP500 único por los once sectores GICS del índice (Energy, Financials, Information Technology, Health Care, Industrials, etc.), cada uno como un nodo independiente con sus propias features (retornos sectoriales, volatilidad, peso en el índice), conectados a los países según su exposición geográfica. Esta opción aportaría una granularidad y una capacidad interpretativa muy superiores. En lugar de afirmar que "Rusia pesó X en la predicción del SP500", el modelo permitiría afirmar que "Rusia pesó X en Energy, Y en Industrials, Z en Consumer Staples", lo cual conecta

directamente con el concepto de momentum spillover descrito en el estado del arte (Patel et al. 2025). La interpretabilidad resultante sería excepcional, y permitiría construir análisis casuísticos por sector, identificar qué subconjuntos del mercado son más sensibles a qué tipos de eventos geopolíticos, y validar si la estructura sectorial aprendida por el modelo coincide con la intuición económica.

Esta opción, sin embargo, nos generó dudas serias durante el proceso de discusión. La primera duda fue sobre cómo construir las aristas país-sector. Valoramos tres alternativas. Una opción era conectar todos los países con todos los sectores y dejar que el modelo aprenda los pesos relevantes por atención; esto es viable pero introduce ruido considerable, ya que pasaríamos de unas decenas de aristas país-mercado a varios centenares de aristas país-sector. Una segunda opción era predefinir las aristas a partir de datos de exposición geográfica sectorial: cuánto de las ventas del sector tecnológico del SP500 proviene de China, cuánto del sector energético depende de Oriente Medio, y así sucesivamente. El problema es que estos datos no están disponibles de forma gratuita y limpia: las fuentes profesionales (FactSet, Refinitiv) son de pago, y las aproximaciones gratuitas (flujos comerciales de UN Comtrade) son imperfectas y requieren un trabajo de validación considerable. La tercera opción consistía en aristas dinámicas activadas por los temas tratados en los eventos GDELT, utilizando el Global Knowledge Graph (GKG) para mapear eventos a sectores según su contenido temático (eventos sobre petróleo a Energy, eventos sobre semiconductores a Information Technology, etc.). Esta última opción es elegante pero requiere incorporar el GKG al flujo de trabajo, lo cual implica trabajo adicional considerable: el GKG es significativamente más voluminoso que Events 2.0 (varios gigabytes diarios sin filtrar), su estructura interna es más compleja (campos serializados que requieren parsing), y exige construir un mapeo temas-sectores que también debe defenderse metodológicamente.

La segunda duda fue sobre la viabilidad temporal. Al sumar todas estas decisiones (definir 11 nodos sectoriales, decidir cómo construir cada conjunto de aristas, validar la matriz de exposición resultante, incorporar el GKG al flujo de trabajo si optamos por la opción de aristas dinámicas, ampliar la cabeza de predicción de un nodo a once...), el coste adicional sobre la opción de un único nodo SP500 sería muy significativa. En un Trabajo Fin de Máster con plazo finito, esta inversión introduce un riesgo real de no llegar a entrenar el modelo a tiempo, o de tener que recortar la fase de evaluación, lo cual sería peor que un modelo más

simple bien evaluado. Discutimos también el patrón típico del TFM ambicioso que dedica demasiado tiempo a la infraestructura y demasiado poco a los resultados, y consideramos que era un riesgo a evitar.

La tercera duda fue sobre la robustez de la decisión. Incluso si lográramos completar la versión con sectores dentro del plazo, las decisiones metodológicas necesarias (¿qué criterio para conectar país-sector? ¿qué mapeo temas-sector? ¿cómo agregar las once predicciones sectoriales en la predicción del SP500 agregado?) constituirían superficie adicional de exposición ante el tribunal: cada decisión defendible es también una decisión que puede cuestionarse. La opción del nodo único, en comparación, presenta una superficie metodológica mucho menor.

Por último, valoramos también el coste de oportunidad en relación con la migración futura. Discutimos qué supondría comenzar con el nodo único SP500 y, si los resultados lo justificasen, ampliar posteriormente a sectores GICS. Esta migración resulta significativamente más sencilla que partir de cero, ya que la mayor parte de la infraestructura del flujo de trabajo se mantiene: la ingesta de GDELT, la construcción del grafo geopolítico, el mecanismo de decay temporal, la familia arquitectural HGNN y el bucle de entrenamiento son reutilizables. Lo único que se modificaría es la estructura interna de los nodos de tipo mercado (uno frente a once) y la cabeza de predicción. Esta posibilidad de evolución incremental refuerza la decisión: empezar con la opción más sólida y manejable, dejando la versión sectorial como línea natural de trabajo futuro identificada explícitamente en las conclusiones.

Con todas estas consideraciones, la elección final fue integrar el SP500 como un único nodo dentro del grafo heterogéneo. Esta opción combina el cruce profundo entre modalidades que late fusion no ofrece, la interpretabilidad vía atención, una diferenciación clara frente al estado del arte, y un nivel de complejidad compatible con los plazos de un Trabajo Fin de Máster. La versión con sectores GICS queda identificada como continuación natural del trabajo.

4.2.3 Arquitectura del modelo: familia HGNN

La elección de integrar el SP500 como nodo en el grafo determina automáticamente la familia de arquitecturas a utilizar. Al tener dos tipos de nodos diferentes (países y mercado),

con features de naturalezas distintas, y dos tipos de aristas (país-país y país-mercado), el grafo es heterogéneo por construcción. Las GNN homogéneas estándar (GCN, GAT, GraphSAGE) no son aplicables directamente porque asumen que todos los nodos comparten el mismo espacio de features y todas las aristas tienen la misma semántica.

Dentro de las Heterogeneous Graph Neural Networks (HGNN) existen varias arquitecturas relevantes. R-GCN (Relational GCN) extiende la GCN clásica utilizando una matriz de pesos distinta para cada tipo de relación, pero carece de mecanismo de atención, limitando tanto la interpretabilidad como la capacidad del modelo de modular dinámicamente la importancia de cada arista. HAN (Heterogeneous Attention Network) utiliza atención a dos niveles pero requiere definir metapaths predefinidos, es decir, secuencias de tipos de relaciones (por ejemplo, país-evento-país), lo que añade decisiones metodológicas que para un grafo relativamente simple como el nuestro resultan innecesarias. HGT (Heterogeneous Graph Transformer) y HeteroGAT son las dos arquitecturas que mejor encajan con los objetivos del trabajo: ambas incorporan atención específica por tipo de arista, lo que las hace adecuadas tanto para capturar la importancia variable de cada interacción como para producir resultados interpretables.

Finalmente optamos por HeteroGAT. Ambas opciones son viables y la diferencia entre ellas es pequeña: HGT aporta algo más de expresividad, al aplicar atención específica por tipo de nodo además de por tipo de arista, pero esa capacidad adicional no compensa el trabajo que supone, y HeteroGAT permite avanzar más rápido en el desarrollo. Si los resultados lo justificasen, migrar a HGT sería directo, ya que basta con sustituir la clase de capa.

La implementación emplea GATv2 (Brody et al., 2022) en lugar del GAT original. El GAT original ordena a los vecinos por importancia de la misma forma para todos los nodos, sin que ese orden dependa de cuál de ellos esté recibiendo la información, y GATv2 elimina esa restricción: permite al modelo ponderar cada arista según el contexto de la predicción. Cada tipo de relación tiene su propia operación de atención, y HeteroConv aplica cada una de forma independiente sobre su subgrafo, combinando después la información que recibe cada nodo.

4.2.4 Diseño topológico de nodos y aristas

Una vez fijada la familia arquitectural, surgieron varias decisiones de diseño sobre la estructura concreta del grafo. Estas decisiones no son evidentes a priori y requirieron deliberación.

Sobre el número de nodos. GDELT registra eventos para más de doscientos países y territorios. Una primera intuición era incluir todos ellos como nodos, dejando que el modelo aprendiera por sí mismo qué países son relevantes para el SP500. Sin embargo, identificamos un problema importante: si la mayoría de los nodos son irrelevantes para el target la mayor parte del tiempo, los mensajes geopolíticamente significativos (los provenientes de Estados Unidos, China, Rusia, etc.) se diluyen en un mar de ruido proveniente de países cuyos eventos rara vez tienen impacto medible en el mercado estadounidense. Esto reduce la relación señal-ruido del grafo y obliga al modelo a invertir capacidad en aprender que la mayoría de países son irrelevantes, en lugar de afinar las relaciones que sí importan. Por esta razón se decidió trabajar con un conjunto reducido de veinte nodos seleccionados por su relevancia económica y geopolítica para el SP500. Esta decisión no se aplica solo a la eficiencia computacional, sino sobre todo a la calidad de la señal que recibe el modelo.

Sobre entidades supranacionales. Algunos actores geopolíticos no se ajustan al concepto de país individual, pero tienen efectos directos en los mercados. Discutimos especialmente tres casos. La Unión Europea se decidió incluir como nodo independiente porque GDELT etiqueta directamente eventos a la UE como entidad, sus decisiones económicas (política monetaria del BCE, sanciones, regulación) tienen efecto inmediato sobre los mercados, y agregar esos eventos a los países miembros distorsionaría su significado. La OTAN, en cambio, se decidió no incluir: aunque toma decisiones colectivas relevantes, presenta un solapamiento informacional significativo con Estados Unidos (la mayor parte de eventos OTAN coinciden con eventos estadounidenses), y esa información se captura mejor a través del tipado de aristas militares entre USA y otros países.

Sobre subnodos institucionales dentro de Estados Unidos. Al ser Estados Unidos el país sobre cuyo mercado se realiza la predicción, surgió la pregunta de si convendría representarlo con mayor resolución interna, mediante subnodos del tipo Pentágono, Reserva Federal, Congreso o Silicon Valley. Discutimos esta opción con cierto detalle. La motivación era capturar la heterogeneidad interna de un actor que es a la vez militar, monetario, legislativo y

empresarial. Sin embargo, el análisis técnico mostró que esta descomposición no aporta capacidad expresiva real sobre la alternativa de tener un único nodo Estados Unidos con aristas tipadas según la naturaleza del evento. Si una arista USA-Rusia refleja mayoritariamente eventos de conflicto material (ataques, sanciones, movilizaciones), el mecanismo de atención de GATv2 puede aprender a tratarla de forma distinta a una arista USA-Reino Unido dominada por cooperación material (acuerdos, ayuda, coordinación económica), sin necesidad de fragmentar Estados Unidos en subnodos. Añadir subnodos significaría introducir parámetros adicionales y decisiones metodológicas difíciles de justificar sin un beneficio claro en términos de expresividad del modelo.

Sobre la topología de aristas país-SP500. Aquí también consideramos varias alternativas. La opción más sencilla era conectar todos los países al SP500 con peso uniforme, dejando que el modelo aprendiera por atención cuáles son más relevantes. La opción opuesta consistía en conectar solo Estados Unidos al SP500, dejando que la información del resto del mundo llegue al mercado a través de Estados Unidos vía sucesivas iteraciones del message passing. Una tercera alternativa consistía en aristas dinámicas que se activan solo los días en que un país tiene eventos relevantes. Finalmente optamos por una opción intermedia: todos los países conectados al SP500, pero con pesos iniciales informados por el comercio bilateral con Estados Unidos. Estos pesos son estimaciones propias de orden de magnitud, expresadas como fracción del comercio exterior total estadounidense y fijadas a mano a partir de la distribución conocida de socios comerciales de USA en el periodo del estudio; no proceden de una única fuente citable, y su sustitución por datos oficiales de UN Comtrade o del U.S. Census Bureau queda identificada como mejora futura. Con este prior razonable el modelo converge más rápido y se evita el cuello de botella que supondría que toda la información del mundo tuviera que pasar por la representación vectorial de Estados Unidos antes de llegar al mercado; a la vez, se mantiene la posibilidad de que el mecanismo de atención refine implícitamente esos pesos durante el entrenamiento. Los pesos en sí no son entrenables: lo que el modelo aprende es cómo combinar la información de las aristas con el resto del grafo. La opción de aristas dinámicas se identifica también como mejora futura.

Sobre el tipado de las aristas país-país. Dado que GDELT clasifica cada evento según los códigos CAMEO, surgió la pregunta de si tratar todas las aristas como genéricas o tipificarlas según la naturaleza del evento. Optamos por la segunda opción. El tipado permite al modelo

separar los eventos según los cuatro cuadrantes de QuadClass —cooperación verbal, cooperación material, conflicto verbal y conflicto material—, sin necesidad de añadir subnodos institucionales. Esta granularidad separa una amenaza de un ataque y un pacto firmado de un mero comunicado, aunque agrupe bajo «conflicto material» sucesos tan distintos como una sanción económica y un despliegue militar. La resolución más fina que ofrecería EventRootCode se descarta en §4.2.5 por el régimen de datos.

El nivel de granularidad del tipado se resolvió con las cuatro categorías de QuadClass, a partir del volumen de eventos por categoría sobre el dataset filtrado. La Tabla X recoge ese reparto. En número de eventos la distribución es muy desigual, con la cooperación verbal concentrando el 63,3 % del total, pero el reparto de aristas resulta bastante más equilibrado: ninguna de las cuatro categorías baja del 19,3 %, y la menos frecuente sostiene 423.939 aristas a lo largo del periodo. Las veinte categorías de EventRootCode fragmentarían ese volumen hasta dejar sin masa apreciable a las de cola.

QuadClass	Eventos	% eventos	Aristas	% aristas
1. Cooperación verbal	14.053.684	63,3 %	862.753	39,2 %
2. Cooperación material	2.444.943	11,0 %	462.327	21,0 %
3. Conflicto verbal	2.867.687	12,9 %	449.638	20,5 %
4. Conflicto material	2.827.610	12,7 %	423.939	19,3 %
Total	22.193.924	100,0 %	2.198.657	100,0 %

Tabla X. Distribución de eventos y aristas por QuadClass en el periodo 2015-2025.

Nota. Los porcentajes de eventos no suman exactamente 100 por efecto del redondeo.

Fuente: Elaboración propia a partir de GDELT 1.0 (2015-2025).

4.2.5 Régimen de datos y dimensionamiento del modelo

Una consideración transversal que condiciona el diseño completo es el régimen de datos en el que opera el problema. Con diez años y medio de datos diarios (2015-2025) y un esquema de validación walk-forward, el dataset final son 2.751 grafos; el tamaño efectivo del train

varía por fold entre unas 250 y 2.500 muestras al operar en modo expansivo. En el contexto del deep learning moderno, esta cantidad es modesta. La heurística común sugiere disponer al menos de diez a cien veces más muestras que parámetros entrenables del modelo. Con 2.751 grafos, ese criterio sitúa el techo defensible en el orden de los cincuenta a doscientos mil parámetros. La arquitectura finalmente adoptada (§4.3.4) tiene 57.603 parámetros entrenables: 768 en la proyección de nodos país, 640 en la del nodo mercado, 51.840 en las dos capas GATv2 vía HeteroConv, y 4.355 en la cabeza MLP de clasificación. Se opera por tanto en el extremo bajo del margen que la heurística permite, coherente con la decisión de mantener el modelo pequeño para el régimen de datos disponible.

Comparando con trabajos similares en el estado del arte (HATS, Chen et al. 2023, FSTGAT), el régimen es comparable: estos trabajos operan también con cantidades modestas de datos diarios sobre conjuntos limitados de activos, y son técnicamente viables. La conclusión es que el problema no es impracticable, pero sí exige un diseño cuidadoso en varios frentes.

Las decisiones tomadas para mitigar las consecuencias de este régimen son varias. En primer lugar, el modelo se mantiene deliberadamente pequeño, con representación vectorial de dimensión 64 y dos capas de message passing con cuatro cabezas de atención. En segundo lugar, se aplica regularización fuerte: dropout de 0,3, weight decay de $1 \cdot 10^{-4}$, y parada temprana con paciencia de 15 épocas sobre una validación interna —el 15 % final del train de cada fold—, nunca sobre el test. En tercer lugar, los pesos de las aristas país-SP500 se mantienen estáticos (no entrenables) precisamente para no añadir parámetros innecesarios al modelo. En cuarto lugar, la evaluación se realiza con tres semillas aleatorias (0, 1, 2) reportando media y desviación de las métricas, lo que ofrece una visión realista del rendimiento esperado y de su estabilidad. Por último, el esquema de validación walk-forward respeta la naturaleza temporal del problema, evitando el leakage que se produciría con un k-fold estándar.

Reconocer explícitamente el régimen de datos limitados y diseñar el sistema en consecuencia no es una limitación del trabajo sino una decisión metodológica consciente. Un modelo sobredimensionado para los datos disponibles no produciría mejores resultados sino los contrarios: aprendería a memorizar el conjunto de entrenamiento sin generalizar al conjunto de prueba.

Esta limitación en el volumen de datos condiciona directamente la granularidad que podemos permitirnos en el diseño topológico (§4.2.4). Por ejemplo, optar por QuadClass se traduce en un vector one-hot de solo cuatro dimensiones para caracterizar la relación entre países. Si hubiéramos elegido EventRootCode, estaríamos multiplicando por cinco esa dimensión y disparando el número de parámetros a aprender en cada rama de HeteroConv. Con apenas 2.751 grafos disponibles para el entrenamiento, mantener una arquitectura reducida no es solo una preferencia, sino la única vía metodológicamente sólida para evitar el sobreajuste.

4.3 Arquitectura final

Tras justificar en el apartado anterior las decisiones técnicas y las alternativas descartadas, esta sección describe el sistema de forma integrada. Mientras que el apartado de decisiones técnicas respondía al porqué de cada decisión, este describe el qué: la estructura concreta del grafo, su evolución temporal, el modelo que lo procesa y el procedimiento de entrenamiento y evaluación.

4.3.1 Visión general del sistema

El sistema toma como entrada, para cada día de mercado, dos fuentes de información: los eventos geopolíticos registrados por GDELT hasta ese día (ya filtrados según el procedimiento descrito en el apartado 4.1) y el estado financiero del mercado en esa misma fecha. A partir de ellos se construye un grafo heterogéneo que representa el estado del mundo en ese momento: los nodos país recogen la situación de cada actor geopolítico, las aristas entre países recogen sus interacciones recientes con la memoria temporal acumulada, y un nodo de tipo mercado recoge el estado del SP500. Este grafo se procesa mediante una red neuronal de grafos heterogénea (HGNN), que produce una representación vectorial para cada nodo. La representación vectoriales del nodo mercado se utiliza finalmente para predecir la dirección del SP500 en la sesión siguiente, clasificándose en una de tres categorías: subida, bajada o neutro.

A partir del grafo del día t , el sistema produce directamente la predicción para el día $t+1$ sin pasos intermedios de procesamiento manual. La separación entre la construcción del grafo

(que incorpora la lógica de decay temporal) y el modelo que lo procesa permite además experimentar con ambos componentes de forma relativamente independiente.

4.3.2 Estructura del grafo heterogéneo

El grafo se define como un grafo heterogéneo, es decir, un grafo que contiene más de un tipo de nodo y más de un tipo de arista. Además del conjunto de nodos y aristas habituales, se especifican una función que asigna a cada nodo su tipo y una función que asigna a cada arista el suyo.

En cuanto a tipos de nodos, el grafo contiene dos tipos. El primero es el tipo país, que agrupa veinte actores geopolíticos seleccionados por su relevancia para el mercado estadounidense: USA, CHN, RUS, DEU, FRA, GBR, JPN, KOR, IND, TWN, CAN, MEX, BRA, SAU, IRN, ISR, TUR, PRK, AUS y la Unión Europea como única entidad supranacional del conjunto. Esta composición queda cerrada a nivel arquitectónico y su justificación se recoge en §4.2.4. El segundo es el tipo mercado, representado por un único nodo correspondiente al SP500.

En cuanto a aristas, el grafo contiene tres tipos. Las aristas país-país (country-interactua-country) representan las interacciones geopolíticas registradas por GDELT entre dos actores; llevan tipado la naturaleza del evento en forma de one-hot de QuadClass, es decir, la información de CAMEO permite distinguir interacciones cooperativas frente a conflictivas, y a su vez separar cada una en su vertiente verbal (declaraciones, amenazas, comunicados) frente a material (acuerdos firmados, ataques, sanciones). Esta granularidad de cuatro categorías queda cerrada por las razones expuestas en §4.2.4 y §4.2.5. Las aristas país-mercado (country-expone-market) conectan cada nodo país con el nodo SP500 y representan la exposición estructural del mercado a cada actor. Finalmente, las aristas mercado-país (market-influye-country), inversas a las anteriores, permiten que el estado financiero retroalimente a los países durante el message passing: sin esta tercera relación el nodo mercado solo recibiría información y el argumento de interacción bidireccional discutido en §4.2.2 no se sostendría.

En cuanto a características, cada nodo lleva asociado un vector de features que describe su estado. Los nodos de tipo país llevan once features idénticas para todos los actores: tono mediático medio, escala de Goldstein media, logaritmo del número de eventos, logaritmo de

NumMentions, peso de comercio bilateral con Estados Unidos, logaritmos de los grados de entrada y salida, y las cuatro fracciones por categoría de QuadClass. Todos los países comparten el mismo esquema; Estados Unidos no incorpora features macroeconómicas adicionales, y los indicadores de la Reserva Federal y del Tesoro que en el diseño inicial se contemplaba asignarle acabaron en el nodo mercado, tras comprobarse que el modelo aprovechaba mejor esa información desde allí.

El nodo de tipo mercado lleva nueve features de naturaleza financiera: retornos a 1, 5 y 21 días, volatilidad a 21 días, logaritmo del volumen, VIX, logaritmo del índice del dólar (DXY), tasa de fondos federales y rendimiento del bono del Tesoro a 10 años. De estas nueve, tres quedaron inactivas en el experimento presentado: el DXY no se descargó al ciclo definitivo de datos, y las dos macro USA se pusieron a cero mediante `USAR_MACRO = False` tras observarse que empeoraban las métricas de validación. El vector operativo es por tanto de seis dimensiones con datos y tres a cero.

Las aristas país-país llevan siete features: peso con decay, tono ponderado, logaritmo del número de eventos, y las cuatro posiciones del one-hot de QuadClass mencionado en el bloque anterior. Las aristas país-mercado y mercado-país llevan una única feature, el peso de comercio bilateral con Estados Unidos; no se complementa con otras señales económicas. A diferencia de los pesos del modelo, todos estos atributos de arista no son parámetros entrenables sino información de entrada.

Las aristas también llevan información asociada. Las aristas país-país incorporan los atributos agregados de los eventos correspondientes (intensidad, tono y volumen de menciones), una vez aplicada la lógica de decay temporal descrita en el siguiente apartado. Las aristas país-mercado incorporan una medida de exposición, cuya base será el comercio bilateral con Estados Unidos, posiblemente complementada con otras señales de relevancia económica. A diferencia de los pesos del modelo, estos atributos de arista no son parámetros entrenables, sino información de entrada.

4.3.3 Evolución temporal: refuerzo y decaimiento de las aristas

El componente que dota al grafo de memoria temporal es el mecanismo de refuerzo y decaimiento de las aristas país-país inspirado en los procesos de Hawkes. En esencia, el peso de cada arista se intensifica con cada nuevo evento entre los dos actores y se atenúa gradualmente en su ausencia, de modo que una relación geopolítica mantiene una presencia continua en el grafo en lugar de aparecer y desaparecer con cada noticia.

La intensidad de cada evento se mide a partir de sus features numéricas (tono y Goldstein ponderados) y su decaimiento sigue el esquema exponencial descrito en §4.2.1, con λ base de 0,0693 (vida media de 10 días para la categoría de cooperación material) modulada por los multiplicadores 1,5 / 1,0 / 0,7 / 0,4 de QuadClass, que llevan la vida media efectiva al rango 6,7-25 días. Estos valores se han fijado a priori a partir del razonamiento sobre las tres fases del riesgo geopolítico expuesto en §4.2.1 y no se han sometido a barrido sistemático; una exploración empírica de λ y de los multiplicadores por categoría queda identificada como línea de trabajo futuro en §7.2.

A diferencia de las aristas país-país, las aristas país-mercado y mercado-país no están sujetas a este mecanismo, ya que representan una exposición estructural y no una interacción puntual. Operativamente, el grafo se reconstruye para cada día de mercado a partir de una ventana de sesenta días de eventos anteriores; conceptualmente, sin embargo, se trata de un único grafo persistente cuya configuración evoluciona en el tiempo, y no de una sucesión de grafos independientes. La ventana de sesenta días se justifica por el criterio de contribución despreciable de los eventos más antiguos: con la λ base, un evento a sesenta días conserva un 2 % de su peso inicial, y aunque en la categoría de conflicto material la fracción retenida asciende al 19 %, la ganancia de mantener eventos aún más antiguos no compensa el coste computacional.

4.3.4 Modelo: red neuronal de grafos heterogénea

El grafo construido para cada día se procesa mediante una red neuronal de grafos heterogénea de la familia basada en atención: HeteroGAT con GATv2Conv (Brody, Alon & Yahav, 2022) envuelto en HeteroConv, con una operación de atención independiente por cada uno de los tres tipos de relación declarados en §4.3.2. Las razones de la elección frente a HGT se recogen en §4.2.3.

El procesamiento sigue el esquema habitual de las redes de grafos. En primer lugar, una capa de proyección inicial transforma las características de cada tipo de nodo, que tienen dimensionalidades y naturalezas distintas, a un espacio de representación común. A continuación se aplican varias capas de paso de mensajes (message passing): en cada capa, cada nodo recibe información de sus vecinos a través de las aristas que lo conectan, pondera esa información mediante el mecanismo de atención, que aprende a asignar más peso a las relaciones más relevantes, y actualiza su propia representación combinando lo que tenía con lo que ha recibido. Tras varias capas, la representación de cada nodo incorpora no solo sus características propias sino también la información de su entorno relacional, incluyendo, en el caso del nodo mercado, la información geopolítica que le ha llegado a través de los países.

Los hiperparámetros que definen el tamaño del modelo se han cerrado consistentes con el régimen de datos descrito en §4.2.5: dimensión oculta de 64, dos capas de paso de mensajes, cuatro cabezas de atención por capa, y dropout de 0,3 entre capas. Dos capas bastan para que la información se propague entre nodos no directamente conectados sin incurrir en sobre-suavizado, dada la topología reducida del grafo (veinte nodos país más el nodo mercado). Sobre las capas de mensaje se aplica una conexión residual que suma la representación previa a la agregada por atención, lo que permite conservar las features propias de cada nodo cuando el mensaje entrante es débil o ruidoso y estabiliza el entrenamiento al reducir la sensibilidad a la inicialización. El bloque residual obliga a que la dimensión oculta sea divisible por el número de cabezas, restricción que $64 / 4$ satisface. Sobre la representación final del nodo mercado se aplica una cabeza MLP de dos capas con dropout intermedio, que produce los tres logits de clasificación. La arquitectura no incorpora ninguna capa de normalización —ni LayerNorm ni BatchNorm—; la regularización se apoya exclusivamente en el dropout, el weight decay ($1 \cdot 10^{-4}$) y la parada temprana descritos en §4.2.5.

4.3.5 Cabeza de predicción y definición del objetivo

Una vez procesado el grafo, se extrae la representación vectoriales final del nodo de tipo mercado, que condensa tanto el estado financiero del SP500 como el contexto geopolítico que ha absorbido durante el paso de mensajes. Esta representación vectoriales se pasa por una capa de clasificación que produce, mediante una función softmax, las probabilidades

asignadas a cada una de las tres clases: bajada, neutralidad y subida. La predicción del modelo es la clase de mayor probabilidad.

La definición operativa de las tres clases requiere fijar los umbrales que delimitan qué se considera «neutralidad» frente a un movimiento significativo al alza o a la baja. La decisión final ha sido usar terciles de la distribución de retornos diarios del SP500: el tercio inferior queda como bajada, el central como neutralidad y el superior como subida. La opción alternativa evaluada, un umbral simétrico basado en una fracción de la desviación típica, se descartó tras comprobarse que dejaba la clase neutra dominante en periodos de baja volatilidad y vacía en periodos de alta volatilidad. Los umbrales de tercil se recalculan de forma independiente en cada fold utilizando únicamente los retornos del train de ese fold, para evitar la filtración de información del test que introduciría un cálculo global.

Como función de pérdida se utiliza la entropía cruzada estándar, sin ponderación por clase (`usar_pesos_clase = False`). El etiquetado por terciles garantiza clases aproximadamente balanceadas por construcción, de modo que la penalización adicional por frecuencia inversa resulta innecesaria y solo introduciría ruido en el gradiente.

Un aspecto crítico en la definición del objetivo es evitar la filtración de información del futuro. En GDELT 2.0 este control exigiría un corte horario, ya que la fuente se actualiza cada quince minutos. En GDELT 1.0, versión utilizada en este trabajo, la fuente publica un único fichero por jornada con marca de tiempo a granularidad de día, sin resolución intradía. Esta cadencia diaria garantiza por construcción la separación temporal: el fichero del día t se publica en la mañana de $t+1$, de modo que la etiqueta —el retorno cierre-a-cierre del SP500 entre t y $t+1$ — se calcula sobre información que en el momento de la decisión aún no habría estado disponible. No es necesario, por tanto, aplicar un corte horario adicional dentro del día para separar información pre y post-cierre.

4.3.6 Entrenamiento y evaluación

El entrenamiento y la evaluación del modelo deben respetar la naturaleza temporal del problema, lo que descarta los esquemas de validación cruzada estándar que mezclan aleatoriamente las muestras: en una serie temporal, entrenar con datos posteriores a los de prueba constituiría una forma de filtración de información. En su lugar se adopta un esquema de validación temporal de tipo walk-forward de diez folds con ventana expansiva: el

modelo se entrena sobre el histórico acumulado desde el inicio del periodo hasta el corte del fold y se evalúa sobre las 250 sesiones bursátiles inmediatamente posteriores, desplazando el corte fold a fold hasta cubrir el rango 2015-2025. Las particiones se miden en muestras (grafos diarios), no en días naturales, y el embargo entre train y test es cero: la contigüidad temporal es defendible porque la etiqueta de un día no depende de la de días posteriores, y un embargo mayor recortaría el train sin aportar garantía adicional.

Dado el régimen de datos limitado, la evaluación se repite con tres semillas aleatorias (0, 1, 2) y se reporta tanto la media como la desviación de las métricas en cada fold, ofreciendo así una imagen realista de la estabilidad del modelo y no únicamente de su mejor resultado puntual.

Como métricas de evaluación se emplean las habituales en clasificación: la exactitud (accuracy), la puntuación F1 macro —métrica principal, dado que pondera por igual las tres categorías y no favorece a la clase mayoritaria— y la matriz de confusión, que permite analizar qué tipos de error comete el modelo. De forma complementaria, se evalúa el modelo desde una perspectiva financiera mediante una estrategia de inversión simulada basada en sus predicciones, cuyos resultados se resumen mediante el ratio de Sharpe y las series de rentabilidad acumulada. El detalle de esta evaluación financiera se recoge en §5.4.

Finalmente, para poder afirmar que la arquitectura propuesta aporta valor, su rendimiento se compara con tres modelos de referencia de complejidad creciente. El primero es un baseline trivial que predice siempre la clase mayoritaria; sirve para fijar el suelo métrico bajo aleatoriedad estratificada. Los otros dos son regresión logística y XGBoost, ambos aplicados sobre las mismas features del grafo aplanadas en un vector plano; permiten comprobar si la estructura relacional añade valor sobre modelos que reciben la misma información sin la topología del grafo. Dos baselines adicionales identificados en la fase de diseño —una LSTM alimentada únicamente con datos financieros y un modelo que combinase datos financieros con una señal geopolítica agregada sin estructura de grafo— no se han construido en este piloto por restricción del alcance del TFM; ambos quedan identificados como línea de trabajo futuro en §7.2, ya que serían los que permitirían aislar de forma limpia la contribución específica de modelar la geopolítica como red frente a añadirla como variable escalar.

5. Descripción de los resultados

Este capítulo expone los resultados directos de la versión final del modelo. Su interpretación se reserva para el capítulo siguiente.

El modelo está preparado para procesar un rango temporal parametrizable. En este caso, los resultados presentados se han obtenido procesando los datos geopolíticos y económicos del rango 2015 a 2025.

La elección de este rango responde a una combinación de criterios metodológicos. En primer lugar, la representatividad de los datos. La estructura del mercado, la composición del S&P 500 y sobre todo la cobertura mediática de GDELT han cambiado sustancialmente a lo largo de las décadas. Aunque GDELT ofrece registros desde 1979, el número de fuentes y de eventos capturados crece de forma acusada con el tiempo, una característica de la propia base ya señalada en el capítulo 2, de modo que los años más recientes presentan una cobertura considerablemente más densa y homogénea. Acotar el estudio a la última década evita mezclar regímenes de cobertura muy dispares y trabajar sobre datos más representativos del entorno actual.

En segundo lugar, la necesidad de disponer de muestras suficientes para el esquema de validación walk-forward, donde cada partición debe contener sesiones bastantes para entrenar y validar de forma significativa. En tercer lugar, y de forma deliberada, la cobertura de regímenes de mercado distintos. El rango incorpora tanto tramos alcistas como la corrección del cuarto trimestre de 2018, el desplome asociado a la COVID-19 en 2020 y el mercado bajista de 2022, de modo que el modelo se evalúa frente a condiciones diversas y no solo en un entorno favorable.

Por último, se ha tenido en cuenta el coste computacional. Cada fichero diario de GDELT contiene entre 100.000 y 300.000 eventos, por lo que ampliar el rango temporal incrementa de forma notable el volumen de datos a descargar y procesar. La extensión del periodo se ha ajustado para equilibrar la representatividad de los datos con la viabilidad del procesamiento.

Sobre este rango, el conjunto de datos resultante se compone de 2.751 grafos diarios, uno por cada sesión bursátil, con su correspondiente etiqueta de dirección del índice para la sesión siguiente. La variable objetivo se define mediante terciles: los retornos se ordenan y

se dividen en tres grupos de igual tamaño, de forma que las clases de bajada, neutralidad y subida quedan balanceadas por construcción. Este criterio garantiza una comparación justa frente al azar y evita el desequilibrio que introduciría un umbral basado en la desviación típica. Los umbrales de los terciles se recalculan de forma independiente en cada partición, utilizando únicamente los datos de entrenamiento.

La evaluación se realiza mediante validación temporal walk-forward, con diez particiones en las que la ventana de entrenamiento se amplía de forma progresiva y la de validación abarca las 250 sesiones siguientes. El proceso se repite con tres semillas de inicialización distintas, lo que arroja un total de treinta experimentos out-of-sample. Todas las métricas presentadas en las tablas siguientes se reportan como media y desviación típica sobre esos experimentos. Los detalles de la arquitectura del modelo, el mecanismo de decaimiento temporal y el protocolo de prevención de fugas de información se describen en el capítulo 4.

5.1. Distribución de los datos

Antes de presentar el rendimiento del modelo conviene describir el conjunto sobre el que opera. La variable objetivo, definida por terciles, reparte las sesiones en tres clases de tamaño equivalente. Sobre el total de predicciones fuera de muestra, la distribución real observada es del 32,6 % para la clase de bajada, el 30,3 % para la de neutralidad y el 37,1 % para la de subida. El ligero desajuste respecto al reparto exacto por tercios se debe a que los umbrales se recalculan de forma independiente en cada partición a partir de sus propios datos de entrenamiento y no sobre la serie completa.

La Figura X muestra esta distribución de clases junto al histograma de los retornos diarios del índice. La serie de retornos presenta una forma marcadamente leptocúrtica, con una fuerte concentración de valores en torno a cero y colas poco pobladas pero extensas. El retorno diario medio del periodo es del 0,05 %, con una desviación típica del 1,13 %, un valor mínimo del -11,98 % de caída y un máximo del 9,52 % de subida. Esta concentración de los movimientos en valores pequeños es característica de las series financieras diarias y condiciona la definición de los umbrales que separan las tres clases.




Figura X. Distribución de las clases de la variable objetivo y de los retornos diarios del S&P 500 en el periodo 2015-2025. Las clases se definen por terciles y sus porcentajes se recalculan de forma independiente en cada partición. Fuente: Elaboración propia.


5.2. Resultados de clasificación

El rendimiento del modelo en la tarea de clasificación constituye el resultado principal de este trabajo. La Tabla X recoge las métricas globales obtenidas como media y desviación típica sobre los treinta experimentos.

Métrica	Valor
Exactitud (accuracy)	0,4124 ± 0,0505
F1-macro	0,3523 ± 0,0440
F1 por clase (baja / neutro / sube)	0,279 / 0,417 / 0,360

Dado que las tres clases están balanceadas por construcción, el valor de referencia correspondiente a una asignación aleatoria se sitúa en torno a 0,33. La exactitud obtenida, del 41,24 %, se sitúa por encima de ese umbral. La puntuación F1-macro, que pondera por igual las tres clases y constituye la métrica principal del estudio, alcanza un valor de 0,3523. Atendiendo al desglose por clases, la clase de neutralidad obtiene la puntuación F1 más alta, con 0,417, mientras que la clase de bajada registra la más baja.

La Figura X presenta la matriz de confusión agregada sobre las 7.500 predicciones fuera de muestra. En ella, las filas corresponden a la clase real y las columnas a la clase predicha.



La clase de neutralidad es la que presenta una mayor proporción de aciertos sobre el total de casos reales, con una exhaustividad (recall) del 58,6 %. La clase de bajada es la que menos se recupera correctamente, con una exhaustividad del 28,4 %, y sus errores se reparten de forma apreciable hacia las otras dos clases. La clase de subida se sitúa en una posición intermedia, con una exhaustividad del 38,3 %. En cuanto a la precisión, los valores por clase son del 34,5 % para bajada, el 42,8 % para neutralidad y el 44,9 % para subida.

5.3. Comparación con los modelos de referencia

Para contextualizar el rendimiento del modelo se ha comparado con un conjunto de modelos de referencia de complejidad creciente, entrenados sobre las mismas características en su forma aplanada, sin la estructura de grafo. La Tabla X recoge esta comparación.

Modelo	Exactitud	F1-macro	F1 (baja / neutro / sube)
Trivial (clase mayoritaria)	0,396	0,189	0,00 / 0,57 / 0,00
Regresión logística	0,340	0,301	0,39 / 0,44 / 0,08
XGBoost	0,352	0,325	0,31 / 0,19 / 0,48
Modelo GNN	0,412	0,352	0,28 / 0,42 / 0,36

El modelo trivial, que asigna siempre la clase mayoritaria, obtiene una exactitud aparentemente elevada pero una F1-macro muy baja, de 0,189, al no predecir nunca dos de las tres clases. Los modelos de aprendizaje automático clásico, regresión logística y XGBoost, mejoran esa puntuación hasta 0,301 y 0,325 respectivamente. El modelo GNN alcanza una F1-macro de 0,352, superior a la de los tres modelos de referencia. Sobre el conjunto completo de predicciones fuera de muestra, su exactitud del 41,24 % también supera a la del modelo trivial equivalente, que sobre ese mismo conjunto se sitúa en el 37,08 %.

Cabe señalar que los modelos de referencia se han evaluado sobre la primera partición, mientras que las métricas del modelo GNN corresponden al agregado de los treinta experimentos, por lo que la comparación tiene carácter indicativo. Evaluado de forma aislada sobre esa misma primera partición, el modelo GNN obtiene una F1-macro de 0,356, igualmente por encima de los tres modelos de referencia.


5.4. Resultados de la evaluación financiera

De forma complementaria a las métricas de clasificación, se ha evaluado el modelo desde una perspectiva financiera, simulando una estrategia de inversión basada en sus predicciones. Los resultados se recogen en la Tabla X.

Métrica	Valor
---------	-------

Rentabilidad de la estrategia	+8,07 % $\pm$ 12,25 %
Rentabilidad buy and hold	+13,32 % $\pm$ 14,56 %
Diferencia frente a buy and hold	5,25 pp $\pm$ 11,27 pp
Ratio de Sharpe	0,82 $\pm$ 1,13
Máxima caída (drawdown)	11,07 % $\pm$ 9,33 %

La estrategia derivada de las predicciones del modelo obtiene una rentabilidad media del 8,07 %, frente al 13,32 % de una estrategia de comprar y mantener el índice durante el mismo periodo. La diferencia media es de 5,25 puntos porcentuales a favor de esta última. El ratio de Sharpe medio es de 0,82, con una desviación típica elevada, y la máxima caída registrada se sitúa en torno al 11 %.



La Figura X muestra las curvas de capital de la estrategia frente a la referencia de comprar y mantener, para cada una de las particiones.

Adicionalmente, se ha realizado un barrido sobre el umbral de confianza a partir del cual la estrategia toma posiciones cortas. La Tabla X recoge la rentabilidad acumulada, el ratio de Sharpe, la máxima caída y el número de posiciones cortas resultantes para distintos valores

de dicho umbral, junto a la rentabilidad acumulada de comprar y mantener durante el mismo periodo, del 3.160,6 %.

Umbral	Rentabilidad	Sharpe	Máxima caída	Nº cortos
0,40	+495,6 %	0,44	61,5 %	1.356
0,50	+703,5 %	0,52	47,8 %	270
0,60	+801,0 %	0,55	44,4 %	69
0,70	+791,0 %	0,55	43,0 %	15
0,80	+824,9 %	0,56	43,0 %	2

Debe tenerse en cuenta que estas rentabilidades acumuladas se calculan sobre la concatenación de las distintas particiones y semillas, cuyos periodos se solapan, por lo que constituyen valores indicativos y no una rentabilidad real sostenida.

5.5. Análisis complementarios de las predicciones

Más allá de las métricas agregadas, se han realizado varios análisis sobre el conjunto de predicciones fuera de muestra que caracterizan con mayor detalle el comportamiento del modelo.

En cuanto a la confianza de las predicciones, medida como la probabilidad máxima asignada por el modelo, su valor medio es de 0,434. El 37 % de las predicciones se emiten con una confianza inferior a 0,40, mientras que solo el 1 % supera el 0,70. La Tabla X relaciona los distintos tramos de confianza con la exactitud realmente observada en cada uno de ellos.

Tramo de confianza	Nº predicciones	Exactitud observada
[0,33 – 0,40)	2.753	0,360
[0,40 – 0,50)	3.650	0,444
[0,50 – 0,60)	903	0,441
[0,60 – 0,70)	142	0,437

[0,70 – 1,00)	52	0,442
---------------	----	-------

La exactitud observada aumenta desde el tramo de menor confianza, con un 0,360, hasta el tramo intermedio, en torno a 0,44, y se mantiene estable a partir de ese punto sin incrementarse en los tramos de mayor confianza.

Respecto a la relación entre acierto y magnitud del movimiento, el retorno absoluto medio de las sesiones en las que el modelo acierta la dirección es del 0,969 %, frente al 0,930 % de aquellas en las que falla. La proporción del movimiento total del mercado capturada por la estrategia, medida como cociente entre el retorno neto capturado y el movimiento absoluto disponible, es de 0,027.

Por último, se ha examinado el carácter de las sesiones clasificadas como neutralidad. El modelo asigna esta clase a 3.115 sesiones, cuyo retorno absoluto medio es del 0,434 %, frente al 0,950 % del resto de sesiones.

5.6. Síntesis de los resultados

De la exposición anterior se desprenden los siguientes resultados. En la tarea de clasificación, el modelo alcanza una exactitud del 41,24 % y una F1-macro de 0,352 sobre tres clases balanceadas, situándose por encima del nivel correspondiente al azar y de los modelos de referencia considerados. La clase de neutralidad es la que el modelo identifica con mayor fiabilidad, mientras que la de bajada es la de menor exhaustividad. En la evaluación financiera, la estrategia basada en las predicciones no supera a la referencia de comprar y mantener durante el periodo analizado. Los análisis complementarios muestran que la exactitud no aumenta en los tramos de mayor confianza y que las sesiones clasificadas como neutralidad presentan un retorno absoluto medio inferior al del resto. La interpretación de estos resultados se aborda en el capítulo siguiente.

6. Discusión

Una vez expuestos los resultados en el capítulo anterior, este se dedica a interpretar su significado, a proponer explicaciones para los comportamientos observados y a situar los hallazgos en el contexto del estado del arte.

El modelo obtenido supera al azar, al modelo trivial y a los modelos de referencia clásicos en F1-macro. Este resultado indica la presencia de una señal aprovechable en los datos, si bien el diseño experimental no permite atribuir con certeza esa mejora a un componente concreto, ya sea la estructura de grafo, la información geopolítica o la mayor flexibilidad del modelo. Aislar la contribución de cada uno requeriría modelos de referencia adicionales que no se han construido en este piloto debido a la simplificación del proyecto para poder encuadrarlo en la estructura de un trabajo de fin de máster.

Conviene subrayar, no obstante, que en un trabajo de naturaleza experimental la presencia de señal estadística no constituye un fin en sí mismo, sino un medio para valorar si el enfoque tiene recorrido. Que el modelo supere al azar demuestra que ha captado alguna estructura real en la relación entre los eventos geopolíticos y el comportamiento del índice, pero detectar esa estructura y convertirla en una ventaja aprovechable son cuestiones distintas. Una señal puede ser estadísticamente real y, al mismo tiempo, demasiado débil para traducirse en utilidad práctica, que es precisamente lo que reflejan los resultados de este trabajo. La estructura detectada es real pero limitada, insuficiente para sostener una ventaja aprovechable, como se desprende de la evaluación financiera y del análisis de la capacidad predictiva del modelo.

Por ello, durante la realización de este proyecto se ha distinguido con claridad entre dos problemas de distinta naturaleza. El primero es la captación de la información diaria y su representación en un grafo capaz de reflejarla de forma útil para la aplicación de técnicas de aprendizaje automático. El segundo es la traducción de esa representación en una ventaja económica dentro de un mercado tan exigente y complejo como el financiero. Se trata de dos retos independientes, y resolver el primero no garantiza en modo alguno resolver el segundo, especialmente cuando la salida del modelo se limita a una predicción triclase de la dirección del índice para la sesión siguiente.

Esta dificultad para traducir la señal en beneficio se manifiesta con claridad en la evaluación financiera. La estrategia derivada de las predicciones del modelo obtiene una rentabilidad media del 8,07 %, frente al 13,32 % de una estrategia de comprar y mantener el índice durante el mismo periodo, lo que supone una diferencia de 5,25 puntos porcentuales a favor de esta última. Esta desventaja se confirma al considerar el riesgo asumido, ya que el ratio de Sharpe, de 0,82, se sitúa por debajo del umbral que suele considerarse aceptable y presenta además una dispersión muy elevada entre ejecuciones, con una máxima caída media en torno al 11 %.

Conviene, no obstante, matizar el alcance de esta comparación. La estrategia de comprar y mantener no constituye una estrategia inteligente, sino la simple permanencia en el mercado, y en un periodo tan marcadamente alcista como el analizado parte con una ventaja estructural difícil de superar. En un contexto en el que el índice sube de forma sostenida, cualquier jornada en la que el modelo decide no mantener la posición se traduce con frecuencia en una oportunidad de ganancia perdida. Por ello, la superioridad de comprar y mantener en este periodo dice menos de lo que parece sobre la calidad del modelo, y debe entenderse como una referencia fuertemente dependiente del régimen de mercado.

Ahora bien, esta consideración no puede emplearse para justificar el resultado, ya que el modelo tampoco demuestra la capacidad de anticipar las caídas. La clase de bajada presenta una exhaustividad del 28 %, de modo que el modelo solo identifica correctamente algo menos de tres de cada diez jornadas de descenso real. No existe, por tanto, evidencia de que el modelo protegería mejor la inversión en un mercado bajista, precisamente porque su mayor debilidad reside en la detección de las bajadas.

Esta limitación se refleja también en la relación entre acierto y magnitud del movimiento. El retorno absoluto medio de las sesiones en las que el modelo acierta la dirección, del 0,969 %, es prácticamente idéntico al de aquellas en las que falla, del 0,930 %, y la proporción del movimiento total del mercado capturada por la estrategia es de apenas 0,027. El modelo no acierta, por tanto, de forma preferente en las jornadas de mayor magnitud, que son las que determinan el resultado económico. Aunque llegue a acertar la dirección en algunas ocasiones, no lo hace donde realmente importa.

No obstante, el análisis detallado de las predicciones revela también un comportamiento coherente y significativo, relativo a la clase de neutralidad. Las sesiones que el modelo clasifica dentro de esta clase presentan un retorno absoluto medio del 0,434 %, muy inferior al 0,950 % del resto de jornadas. Esto indica que la neutralidad no funciona como una categoría residual en la que el modelo acumula las predicciones de las que no está seguro, sino como una identificación real de las sesiones de menor movimiento.

Este comportamiento sugiere que la señal contenida en la actividad geopolítica podría alinearse mejor con la magnitud del movimiento que con su dirección, dos dimensiones distintas de un mismo fenómeno. Una jornada de fuerte tensión internacional tiene una probabilidad elevada de ser volátil, aunque el sentido concreto de esa reacción resulte mucho más difícil de anticipar. El planteamiento inicial, orientado a la dirección, ha permitido observar que la señal disponible parece ajustarse mejor a la magnitud, un aprendizaje que no formaba parte de las expectativas de partida y que constituye una de las aportaciones propias de un trabajo de carácter exploratorio.

Ahora bien, este resultado no debe interpretarse de forma cerrada. Que el modelo capte mejor el régimen que la dirección puede deberse a causas de naturaleza muy distinta, que conviene diferenciar. En primer lugar, podría tratarse de una característica del propio problema, si la dirección del índice a un día de horizonte resulta intrínsecamente menos predecible desde la información geopolítica que la magnitud de su movimiento. En segundo lugar, podría atribuirse a la arquitectura y a su ajuste, ya que un modelo sobredimensionado para el volumen de datos disponible o una configuración de hiperparámetros no óptima podrían impedir la extracción de una señal direccional que sí estuviera presente. Y en tercer lugar, podría deberse a decisiones de diseño previas, como la elección del activo, el horizonte temporal o la resolución diaria de los datos, que condicionan la señal antes incluso de que intervenga el modelo.

Este piloto no permite determinar con certeza cuál de estas causas tiene mayor peso, ni descartar que actúen de forma combinada. Si bien durante el desarrollo del trabajo se exploraron distintas configuraciones del modelo y se ajustaron sus principales hiperparámetros, una atribución rigurosa de las causas exigiría un análisis más exhaustivo, con un barrido sistemático del espacio de hiperparámetros y la comparación formal con

arquitecturas alternativas, que excede el alcance de este trabajo. Conviene subrayar, en cualquier caso, que esta incertidumbre sobre el origen del comportamiento no contradice la existencia de la señal detectada, que se sostiene sobre la superioridad del modelo frente al azar y a los modelos de referencia. La cuestión abierta no es si el modelo capta información, sino por qué la capta mejor en una dimensión que en otra.

El análisis de los resultados revela tres comportamientos que merecen una explicación más detallada: el bajo rendimiento en la clase de bajada, la escasa fiabilidad de la confianza del modelo y la variabilidad entre ejecuciones.

1. La clase de bajada es la más problemática en cuanto a detectarla correctamente, para esta clase rondamos un Recall de 0.28, por tanto de diez bajadas que ocurrieran nuestro modelo solo detectaría menos de tres. Esto puede deberse fundamentalmente a dos motivos distintos:

El primero tiene que ver con la naturaleza de las bajadas durante el periodo de entrenamiento utilizado. Aunque el reparto por terciles garantiza que haya tantas jornadas de bajada como del resto de clases, en un periodo mayoritariamente alcista muchas de ellas son descensos suaves, y las caídas realmente contundentes, con un patrón reconocible del que el modelo podría aprender, son escasas. De la misma manera que ocurre en la detección de anomalías, cuando el fenómeno que se busca predecir está poco representado resulta más difícil de detectar.

Por otro lado, el otro motivo puede tratarse de la naturaleza de la detección de caídas, que en finanzas suelen ser mucho más bruscas, rápidas y reactivas que las subidas. El elemento pánico que rara vez influye en cualquier subida puede provocar muchas más alteraciones artificiales que un grafo basado en geopolítica le costaría más identificar. Ambas razones pueden estar ocurriendo a la vez y no denotarían un fallo en la arquitectura, más bien un fallo en la manera de aplicarla al problema enfrentado.

2. La escasa fiabilidad del modelo es algo también a tener en cuenta, la confianza en una predicción es la probabilidad estimada de que la predicción asignada a una clase sea la correcta. El modelo para cada día reparte una probabilidad entre las tres clases a predecir y elige la más alta como su elección, ese % es su confianza. Por ello de estar bien calibrado podríamos observar como el % de confianza debería solaparse

con el % de acierto, es decir, que la confianza declarada coincide con el acierto observado. En nuestro caso si miramos la tabla de calibración expuesta en el apartado 5.5, vemos la baja mejora que hay entre los umbrales de confianza y acierto. Por ello entendemos que la confianza del modelo por ahora no es fiable, lo cual creemos que puede darse por la debilidad de la señal geopolítica y por la sobredimensionalidad del modelo, un modelo con demasiada capacidad para pocos datos tiende a dar estimaciones de probabilidad poco fiables.

3. La variabilidad entre semillas junto con todo lo demás expuesto nos sugieren que el modelo es aún inestable, los resultados entre semillas oscilan bastante y las desviaciones son grandes. Es decir, que su resultado depende en parte de la suerte del arranque, no solo de lo que aprende de los datos, un modelo robusto daría prácticamente lo mismo con cualquier semilla. La razón principal creemos que vuelve a ser la sobredimensionalidad del modelo.

Las tres anomalías siendo distintas apuntan al mismo problema: demasiados pocos datos para la complejidad del modelo. La bajada se aprende mal porque hay pocos ejemplos y el modelo es frágil. La calibración falla porque un modelo grande con pocos datos da probabilidades poco fiables. La variabilidad existe porque con esa proporción el arranque aleatorio pesa demasiado. Conviene matizar, en cualquier caso, qué se entiende aquí por escasez de datos. Una década constituye un volumen razonable en términos absolutos, de modo que el problema no reside en la cantidad de datos sino en su proporción respecto a la complejidad del modelo. Reducir esa complejidad sin perder la esencia del enfoque es un equilibrio delicado, que se plantea como línea de trabajo futuro. Nos encontramos, en definitiva, ante un resultado posible en un piloto experimental, que se aborda en profundidad en las conclusiones.

El desajuste entre el modelo y los datos no es, sin embargo, la única dificultad. También se le añade la propia naturaleza del problema, que resulta especialmente compleja cuando la predicción se exige a un horizonte de un solo día. Predecir a un día vista la dirección del mercado es una de las tareas más complejas que hay en finanzas, como se expuso previamente en el marco teórico, la reacción de un mercado no suele ser instantánea u ordenada. Parte de la reacción ya se ha aplicado por información privilegiada ajena al modelo y otra parte se va absorbiendo en las horas, días o semanas posteriores. Por tanto, si

el efecto de un evento se distribuye en el tiempo de esta manera, forzar la predicción a un horizonte de un solo día implica capturar únicamente una fracción de esa señal, y probablemente la más ruidosa. Es decir, le estamos pidiendo a un modelo que de base está sobredimensionado que capture justo el tramo más ruidoso e impredecible de esa absorción.

A las dificultades ligadas al horizonte temporal se añade una última consideración, ya que conviene preguntarse, por último, si el S&P 500 es el activo más adecuado para captar la influencia de los eventos geopolíticos una vez entendidos los resultados obtenidos. Como se ha explicado en capítulos anteriores, la elección del S&P 500 como referencia económica se da por razones de datos e integración. Estados Unidos es el foco con mayor cobertura en GDELT y el S&P 500 tiene amplia historia, lo que maximizaría el volumen de datos posibles a obtener para un modelo que anticipamos complejo. Al ser un activo transparente y bien documentado, evitábamos problemas relacionados con mercados opacos o difíciles de relacionar con el GDELT a la escala que necesitamos. Sin embargo, esa elección orientada a la viabilidad recae sobre un activo cuya naturaleza parece jugar en contra de lo que se quiere medir. No es que la geopolítica no le afecte, es que este efecto parece llegar mucho más diluido de lo que pensábamos. Por ello existen otros activos con una relación más directa con la geopolítica que pueden funcionar mejor en cuanto a evitar la disolución de la señal que el S&P 500 y derivados como el oro o el petróleo. Esta diferencia de sensibilidad mencionada está documentada en la literatura de este trabajo, Caldara e Iacoviello (2022) observan que el riesgo geopolítico afecta con mayor intensidad a los mercados de energía y materias primas que a la renta variable en su conjunto, mientras que Plakandaras et al. (2019) encuentran que el oro es el activo donde ese efecto resulta más nítido, por su papel de refugio. En conjunto, observamos una contraposición entre elegir una opción con más datos pero que diluye más la señal o una opción más directa pero con menos datos obtenibles para nutrirla, probar esta segunda vía podría ser interesante para las líneas de trabajo futuro siempre que se abarque también la problemática de la sobredimensionalidad que sufre a día de hoy esta propuesta.

Una vez interpretadas las razones de los resultados, conviene valorar de forma conjunta las fortalezas y las limitaciones del enfoque adoptado por nuestro trabajo.

Las ventajas mencionadas están explicadas de manera completa y concisa en el capítulo 4:

1. El cruce bidireccional país-mercado permite captar las relaciones cruzadas entre mercado y geopolítica, lo cual sería imposible con otras estructuras más simples discutidas en el capítulo 4.
2. La memoria temporal tipo Hawkes ha resultado determinante para poder encajar la idea de la representación bidireccional, pues necesitábamos captar y representar la naturaleza temporal de las acciones para poder relacionarlas correctamente de manera cruzada respetando el orden temporal de cuando se han producido.
3. La etiqueta por terciles nos ha permitido adaptar el umbral de manera óptima permitiendo una evaluación interpretable y honesta que evita una predominancia del neutro y nos ha ayudado a identificar mejor los avances en el modelo.
4. El protocolo anti-leakage ha sido una de las partes más delicadas de este proyecto, pues en caso contrario los resultados podrían estar inflados o alterados de manera que invalidasen cualquier conclusión o aprendizaje de este proyecto.

En cuanto a las desventajas, la mayoría ya han sido tratadas en párrafos anteriores:

1. Régimen de datos y la sobredimensionalidad. El modelo actual dispone de miles de parámetros al buscar realizar un cruce bidireccional mediante la relación de nodos y aristas geopolíticas con nodos y aristas de mercado. Esto genera un modelo muy demandante de datos de entrenamiento que no somos capaces de satisfacer con GDELT. Como se ha comentado anteriormente esto por sí solo ya genera varias desventajas mencionadas a continuación: como la inestabilidad o la mala calibración.
2. Pesos de comercio aproximados. Las aristas que conectan cada país con el mercado llevan un peso que representa la exposición comercial de ese país con Estados Unidos. Esos pesos no son datos reales extraídos de una fuente oficial, son estimaciones propias debido a la intención de limitar la cantidad de parámetros que tiene un modelo ya de base muy demandante de datos. Esto genera no poder representar de la manera más realista cada relación entre países, pero tampoco creemos que sea muy determinante en relación a otros problemas mucho más importantes.
3. Ausencia del baseline financiero puro. No se han separado en otros modelos de comparación la parte financiera y geopolítica, por lo cual no se puede terminar de medir la implicación de cada uno. Pensamos que esta implicación es temporalmente

variable dependiendo del estado del mundo y que por tanto dependiendo de con qué datos se entrene y de qué momento se podrían llegar a conclusiones erróneas donde se afirma o se niega que uno de los dos es numéricamente irrelevante.

4. Inestabilidad entre ejecuciones. Como se mencionó anteriormente, hay una considerabl

7. Conclusiones y trabajo futuro

7.1. Conclusiones

7.2. Líneas de trabajo futuro

8. Referencias bibliográficas

- Caldara, D., & Iacoviello, M. (2022). Measuring geopolitical risk. *American Economic Review*, 112(4), 1194–1225. <https://doi.org/10.1257/aer.20191823>
- Niu, Z., Wang, C., & Zhang, H. (2023). Forecasting stock market volatility with various geopolitical risks categories: New evidence from machine learning models. *International Review of Financial Analysis*, 89, 102545. <https://doi.org/10.1016/j.irfa.2023.102545>
- Plakandaras, V., Gupta, R., & Wong, W. K. (2019). The effects of geopolitical uncertainty in forecasting financial markets: A machine learning approach. *Algorithms*, 12(1), 1. <https://doi.org/10.3390/a12010001>
- Consoli, S., Barbaglia, L., & Manzan, S. (2020). Using the GDELT dataset to analyse the Italian sovereign bond market. En *MIDAS 2020*, LNAI 12591 (pp. 55–67). Springer.
- Myers, A. et al. (2025). Talking to GDELT through knowledge graphs. *arXiv:2503.07584*.

- Bacry, E., Mastromatteo, I., & Muzy, J.-F. (2015). Hawkes processes in finance. *Market Microstructure and Liquidity*, 1(1), 1550005. <https://doi.org/10.1142/S2382626615500057>
- Hawkes, A. G. (1971). Spectra of some self-exciting and mutually exciting point processes. *Biometrika*, 58(1), 83–90. <https://doi.org/10.1093/biomet/58.1.83>
- Fallahi, F. (2017). Machine learning on big data for stock market prediction [Tesis de máster, Southern Illinois University Carbondale]. OpenSIUC. <https://opensiuc.lib.siu.edu/theses/2178/>
- Bao, W., Cao, Y., Yang, Y., Che, H., Huang, J., & Wen, S. (2025). Data-driven stock forecasting models based on neural networks: A review. *Information Fusion*, 113, 102616. <https://doi.org/10.1016/j.inffus.2024.102616>
- Gerner, D. J., Schrod, P. A., Yilmaz, Ö., & Abu-Jabr, R. (2002). *Conflict and Mediation Event Observations (CAMEO): A new event data framework for the analysis of foreign policy interactions*. Presentado en la Annual Meeting of the International Studies Association, New Orleans.
- Euler, L. (1736). Solutio problematis ad geometriam situs pertinentis. *Commentarii Academiae Scientiarum Petropolitanae*, 8, 128–140.
- Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417. <https://doi.org/10.2307/2325486>
- Knight, F. H. (1921). *Risk, uncertainty and profit*. Houghton Mifflin.
- Leetaru, K., & Schrod, P. A. (2013). GDELT: Global data on events, location, and tone, 1979–2012. Presentado en la *Annual Meeting of the International Studies Association*, San Francisco.
- Patel, M., Jariwala, K., & Chattopadhyay, C. (2025). A systematic review on graph neural network-based methods for stock market forecasting. *ACM Computing Surveys*, 57(2), Article 34. <https://doi.org/10.1145/3696411>
- Kim, R., So, C. H., Jeong, M., Lee, S., Kim, J., & Kang, J. (2019). *HATS: A Hierarchical Graph Attention Network for Stock Movement Prediction*. arXiv:1908.07999.

- Wei, Z.-L., An, H.-Y., Yao, Y., Su, W.-C., Li, G., Saifullah, & Wang, M.-J.-S. (2025). *FSTGAT: Financial Spatio-Temporal Graph Attention Network for Non-Stationary Financial Systems and Its Application in Stock Price Prediction*. *Symmetry*, 17(8), 1344. <https://doi.org/10.3390/sym17081344>
- Wilson, R. J. (1996). *Introduction to graph theory* (4^a ed.). Longman.
- Chen, Z., Zheng, L., Lu, C., Yuan, J., & Zhu, D. (2023). ChatGPT informed graph neural network for stock movement prediction. *arXiv:2306.03763*.
- Shiller, R. J. (2003). From efficient markets theory to behavioral finance. *Journal of Economic Perspectives*, 17(1), 83–104. <https://doi.org/10.1257/089533003321164967>
- **SVM:** Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- **Random Forest:** Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- **LSTM:** Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- **GRU:** Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv:1406.1078*.
- **Transformers:** Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Brody, S., Alon, U., & Yahav, E. (2022). How attentive are graph attention networks? En International Conference on Learning Representations. *arXiv:2105.14491*

- **TFT:** Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748–1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>

ÍNDICE DE ACRÓNIMOS

- **ACLED:** Armed Conflict Location & Event Data Project
- **ARIMA:** AutoRegressive Integrated Moving Average
- **BCE:** Banco Central Europeo
- **CAMEO:** Conflict and Mediation Event Observations
- **DXY:** US Dollar Index
- **FIPS:** Federal Information Processing Standards
- **FSTGAT:** Financial Spatio-Temporal Graph Attention Network
- **GARCH:** Generalized Autoregressive Conditional Heteroskedasticity
- **GAT:** Graph Attention Network
- **GDELT:** Global Database of Events, Language, and Tone
- **GICS:** Global Industry Classification Standard
- **GKG:** Global Knowledge Graph
- **GNN:** Graph Neural Network
- **GPR:** Geopolitical Risk
- **GRU:** Gated Recurrent Unit
- **HATS:** Hierarchical Graph Attention Network for Stock Movement Prediction
- **HGNN:** Heterogeneous Graph Neural Network
- **HGT:** Heterogeneous Graph Transformer
- **ICEWS:** Integrated Crisis Early Warning System
- **LDA:** Latent Dirichlet Allocation
- **LSTM:** Long Short-Term Memory
- **ML:** Machine Learning
- **S&P 500:** Standard & Poor's 500
- **SVM:** Support Vector Machine

- **SVR:** Support Vector Regression
- **TFE:** Trabajo Fin de Estudios
- **TFT:** Temporal Fusion Transformer
- **URL:** Uniform Resource Locator
- **VIX:** CBOE Volatility Index

Anexo A. Código fuente y datos analizados